



Synthèse traitement statistique des données

Introduction Au Traitement Statistique Des Données (Haute École de la Province de Liège)



Scanne pour ouvrir sur Studocu

Haute École de la Province de Liège
Bachelier en Informatique de gestion



Traitement statistique des données

Chabeau Corentin

Juin 2022

TABLE DES MATIÈRES

1. Introduction	3
2. Statistique descriptive à 1 dimension	3
2.1. Les variables statistiques	3
2.1.1. Les variables quantitatives	3
2.1.2. Les variables qualitatives	3
2.1.3. Variable statistique	3
2.1.4. Variable aléatoire	3
2.2. Étude statistique d'un caractère quantitatif	4
2.2.1. De manière graphique	4
2.2.2. De manière calculée	5
2.3. La notion de modèle et de distribution	7
3. Les grandes lois statistiques	7
3.1. Lois discrètes	7
3.1.1. Loi binomiale (loi de Bernoulli)	7
3.2. Lois continues	7
3.2.1. La loi normale (loi de Gauss)	7
3.2.2. La loi de Student	8
3.2.3. Loi du chi-carré ou khi-deux	8
3.2.4. Loi de Fisher-Snedecor	9
4. L'inférence statistique classique	9
4.1. Les deux théories réciproques	9
4.1.1. La théorie de l'échantillonnage	9
4.1.2. La théorie de l'estimation	9
4.2. Les distributions d'échantillonnage	9
4.2.1. La distribution d'échantillonnage de la moyenne	9
4.2.2. La distribution d'échantillonnage de la variance	11
4.3. Les tests d'hypothèse	11
4.3.1. Les tests d'hypothèse de conformité	11
4.3.2. Les tests d'hypothèse d'homogénéité	13
4.4. L'analyse de variance à un facteur (ANOVA 1) (Quan~Qual)	15
4.5. L'analyse statistique à deux dimensions (Régression-corrélation) (Quan~Quan)	16
4.5.1. Statistique descriptive	16
4.5.2. Inférence statistique	19
4.6. Le test du chi-carré (Qual~Qual)	21

1. Introduction

- **Big Data** : Étude statistique d'une masse immense et informe de données à manipuler et à analyser.
- **Data Mining (ou Fouille de Données)** : Version moderne du traitement statistique des données qui existe déjà depuis longtemps mais il est ici adapté au fait que les données opérationnelles se trouvent dans des bases de données.
Ensemble de techniques d'**exploration** de données permettant d'extraire d'une **base de données** des connaissances sous la forme de **modèles** de description, afin de **décrire** le comportement actuel et/ou de **prédire** le comportement futur des données.

2. Statistique descriptive à 1 dimension

2.1. Les variables statistiques

2.1.1. Les variables quantitatives

Une **variable quantitative** est une variable qui peut être exprimée par un nombre, une quantité.

Ces variables quantitatives peuvent être divisées en deux sous-catégories :

- **Les variables discrètes** : Une **variable discrète** est une variable qui peut prendre uniquement certaines valeurs d'un intervalle de nombres réels. Généralement, les valeurs admissibles ne sont que les nombres entiers. **Les valeurs sont isolées.**

x_i	n_i
0	16
1	21
2	12
3	4
4	3
5	1
6	3
	60

x_i : Valeurs du caractère étudié
 n_i : Effectifs
 n : Effectif total (ici 60)
 N : Nombre de caractère étudié (ici 7)

- **Les variables continues** : Une **variable continue** est une variable qui peut prendre toutes les valeurs possibles d'un intervalle de nombres réels.

b_i	B_i	c_i	n_i
5000	6000	5500	8
6000	7000	6500	10
7000	8000	7500	16
8000	9000	8500	14
9000	10000	9500	10
10000	11000	10500	5
11000	12000	11500	2
			65

b_i : Bornes inférieures
 B_i : Bornes supérieures
 c_i : Centres de classe
 n_i : Effectifs
 n : Effectif total
 N : Nombre de caractère étudié

2.1.2. Les variables qualitatives

Une **variable qualitative** exprime une valeur qui ne représente pas une quantité.

2.1.3. Variable statistique

Population -> Échantillon (Théorie de l'échantillonnage)

- C'est une variable dont les variables ont été observées.
- Domaine de la **statistique descriptive**.

FRÉQUENCES

2.1.4. Variable aléatoire

Échantillon -> Population (Théorie de l'estimation)

- Prévisions sur la population.
- Domaine de l'**inférence statistique**.

PROBABILITÉS

Les **fréquences** observées de la variable statistique sont interprétées comme les **probabilités** des valeurs de la **variable aléatoire**.

2.1.4.1. Variable aléatoire discrète

x_i	n_i	f_i	nc_i	fc_i
0	16	0,27	16	0,27
1	21	0,35	37	0,62
2	12	0,20	49	0,82
3	4	0,07	53	0,88
4	3	0,05	56	0,93
5	1	0,02	57	0,95
6	3	0,05	60	1,00
	60			

x_i : Valeurs du caractère étudié

n_i : Effectifs

f_i : Fréquences

nc_i : Effectifs cumulés

fc_i : Fréquences cumulées

Espérance mathématique :

On parle de moyenne pour une variable statistique. En revanche, pour une variable aléatoire, on parle de probabilité et donc cela vient de la théorie des jeux avec l'**espérance** de gain.

Une variable aléatoire X discrète se caractérise par :

- **Sa loi de distribution** : $x_i \rightarrow p_i = P(X = x_i)$
Probabilité que la variable aléatoire X soit **égale** à une valeur x_i .
→ Fréquence
- **Sa fonction de répartition** : $x_i \rightarrow F(x_i) = P(X \leq x_i)$
Probabilité que la variable aléatoire X soit **inférieure ou égale** à une valeur x_i .
→ Fréquences cumulées
- Son espérance mathématique
- Son écart-type (ou sa variance)


2.1.4.2. Variable aléatoire continue

Une variable aléatoire X continue se caractérise par :

- **Sa densité de probabilité** : $f(x)$
→ $\int_{-\infty}^{+\infty} f(x).dx = 1$
L'**aire** sous tendue à la courbe **vaut 1**.
Construit sur base de l'**histogramme en densité**.
- **Sa fonction de répartition** : $a \rightarrow F(a) = P(X \leq a) = \int_{-\infty}^a f(x).dx$
 $P(a \leq X \leq b) = F(b) - F(a)$
- Son espérance mathématique
- Son écart-type (ou sa variance)

Dans le cas des **variables continues**, la probabilité d'être pile égale à une valeur est nulle

Calcul de l'aire sous la courbe à l'aide d'une intégrale



2.2. Étude statistique d'un caractère quantitatif

2.2.1. De manière graphique

- Variable discrète
 - Diagramme en bâtons
 - Polygone des effectifs cumulés
 - Diagramme sectoriel
- Variable continue
 - Histogramme

Histogramme en fréquences

Fréquences (effectifs) = **Hauteur** des rectangles

OK seulement si toutes les classes ont la même étendue !

Histogramme en densité
Fréquences (effectifs) = **Aire** des rectangles

- Polygone des effectifs cumulés
- Diagramme sectoriel

2.2.2. De manière calculée

2.2.2.1. *Tendance centrale*

- **La moyenne arithmétique :**

$$m = \bar{x} = \frac{\sum_{i=1}^N x_i}{n}$$

$$m = \bar{x} = \frac{\sum_{i=1}^N n_i * x_i}{n}$$

- **La moyenne arithmétique pondérée :**

$$m = \bar{x} = \frac{\sum_{i=1}^N p_i * x_i}{\sum_{i=1}^N p_i}$$

- **La moyenne géométrique :**

$$\log m_g = \frac{\sum_{i=1}^n \log x_i}{n} = \frac{\log \prod_{i=1}^n x_i}{n} = \log \prod_{i=1}^n x_i^{\frac{1}{n}}$$

$$m_g = \sqrt[n]{\prod_{i=1}^n x_i}$$



Changement de variable :
 $X \rightarrow \log X$

- **La moyenne géométrique pondérée :**

$$\log m_g = \frac{\sum_{i=1}^n p_i \cdot \log x_i}{\sum_{i=1}^n p_i} = \frac{\sum_{i=1}^n \log x_i^{p_i}}{\sum_{i=1}^n p_i} = \frac{\log \prod_{i=1}^n x_i^{p_i}}{\sum_{i=1}^n p_i} = \log \left(\prod_{i=1}^n x_i^{p_i} \right)^{\frac{1}{\sum_{i=1}^n p_i}}$$

$$m_g = \sqrt[\sum_{i=1}^n p_i]{\prod_{i=1}^n x_i^{p_i}}$$

Le logarithme permet d'avoir une représentation beaucoup plus facilement représentable



- **La médiane** : Partage la population en deux parties égales.

$$m_e = b_i + \frac{\frac{n}{2} - \sum_{j=1}^{i-1} n_j}{n_i} * a_i$$

- **Le mode** : La valeur qui a l'effectif le plus grand.

2.2.2.2. Dispersion

- **L'écart type** :

Attention, si on ne met pas au carré, les écarts s'annulent !

En plus de prendre la valeur absolue, le carré permet de mieux prendre compte de la dispersion. **Écarts à la moyenne au carré.**

$$s = \sqrt{\frac{\sum_{i=1}^N n_i \cdot (x_i - \bar{x})^2}{n}}$$

$$s = \sqrt{\frac{\sum_{i=1}^N (x_i - \bar{x})^2}{n}}$$


- **La variance (écart type au carré)** :

$$s^2 = \frac{\sum_{i=1}^N n_i \cdot (x_i - \bar{x})^2}{n} = \frac{\text{SCE}}{n}$$

- **Coefficient de variation** : Ramène l'écart type à la moyenne pour avoir un meilleur ordre de grandeur.
- **Les quantiles** : Valeurs qui divisent la série statistique ordonnée selon l'ordre croissant en parties égales (quartiles (avec médianes), centiles).

2.2.2.3. Forme de la courbe de distribution

- **Coefficient de dissymétrie** :



Les courbes symétriques permettent de fabriquer des intervalles eux-mêmes symétriques et donc de déduire la borne opposée.


Calcul à l'aide du **coefficient d'asymétrie de Fisher**.

Mode < **Médiane** < Moyenne → Asymétrie positive

Moyenne < **Médiane** < Mode → Asymétrie négative

→ **Écarts à la moyenne au cube**

- **Coefficient d'aplatissement** :



"moments"
d'ordre 2,3,4

→ **Écarts à la moyenne exposant 4**

2.3. La notion de modèle et de distribution

De nombreuses variables aléatoires sont régies par des lois spécifiques, définies par une **formule** donnant :

- Soit la probabilité associée à une valeur de X (**variables discrètes**)

$$P(X = x) = C_n^x \cdot p^x \cdot q^{n-x} = \frac{n!}{x!(n-x)!} \cdot p^x \cdot q^{n-x}$$

avec
 $x = 0, 1, 2, \dots, n$ et $0 \leq p \leq 1$

loi binomiale

- Soit la fonction de répartition, c'est-à-dire la probabilité d'observer une valeur inférieure (ou égale) à celle de X.

$$f(X) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2}x^2}$$

où
 $-\infty < X < +\infty$

$$P(X \leq a) = \int_{-\infty}^a f(x) dx = F(a)$$

loi normale

On dit encore que l'on possède une **forme analytique** de ces lois. La loi suivie par une variable aléatoire X est désignée par L(X) en toute généralité.

3. Les grandes lois statistiques

3.1. Lois discrètes

3.1.1. Loi binomiale (loi de Bernoulli)

Elle s'applique à des phénomènes aléatoires pour lesquels on ne peut enregistrer que deux résultats possibles : un succès, de probabilité **p** constante, ou un échec, de probabilité **q** (donc, $q=1-p$).

$$L(X) = B(n;p)$$

3.2. Lois continues


3.2.1. La loi normale (loi de Gauss)

3.2.1.1. La loi normale générale

Remarque :

- La courbe est **symétrique** par rapport à la verticale d'abscisse μ .
- La courbe est d'autant plus **aplatie** que σ est grand.
- L'axe horizontal est une **asymptote**.

La loi normale dépend de μ et σ .



Si $\mu \neq 0$ et/ou $\sigma \neq 1$:

$$f(X) = \frac{1}{\sigma \cdot \sqrt{2\pi}} \cdot e^{-\frac{1}{2} \cdot \left(\frac{X-\mu}{\sigma}\right)^2}$$

où

$$-\infty < X < +\infty$$

3.2.1.2. La loi normale centrée et réduite

$$f(X) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2} \cdot X^2}$$

où

$$-\infty < X < +\infty$$

$$L(X) = Z = N(0;1)$$

$$Z = \frac{X - \mu}{\sigma}$$

Variable aléatoire

Pour transformer une loi normale quelconque en une loi normale centrée et réduite, il faut effectuer un **changement de variable**.

3.2.2. La loi de Student

La loi de Student dépend de ses degrés de liberté (ν).

$$f(t) = c \cdot \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

$$L(X) = St(\nu)$$

Désigne à la fois la **variable aléatoire** qui suit une loi de Student et les **valeurs correspondantes**.

Le paramètre ν est appelé le **nombre de degrés de liberté** qui correspond au nombre d'écarts nécessaires diminué du nombre de restrictions sur ces écarts.

Plus on augmente le nombre de degrés de liberté, plus on se rapproche d'une loi centrée et réduite.

La loi normale est un cas particulier de la loi de Student lorsque le nombre de degré de liberté augmente.

On passe à une loi normale lorsque le nombre de degré de liberté atteint 30.

La distribution est symétrique par rapport à l'origine et est un peu plus aplatie que la distribution normale centrée réduite.

Elle est toujours associée à une somme de carrés. Le plus souvent, il s'agit de carrés d'écarts.

3.2.3. Loi du chi-carré ou khi-deux

$$L(X) = \chi^2(\nu)$$


La loi du chi-carré dépend de ses degrés de liberté (ν).

La distribution du chi-carré est celle d'une quantité, notée χ^2 , définie par :

$$\chi^2 = \sum_{i=1}^{\nu} Z_i^2$$

Forme analytique de la densité de probabilité :

$$f(\chi^2) = c \cdot \chi^{\nu-2} \cdot e^{-\frac{\chi^2}{2}}$$



Traitement statistique des données

$$E(\chi^2) = \nu \quad \text{et} \quad V(\chi^2) = 2\nu$$

3.2.4. Loi de Fisher-Snedecor

La loi de Fisher dépend de ses degrés de liberté (v_1 et v_2).

$$F(v_1, v_2)$$

$$f(x) = c x^{\frac{v_1-1}{2}} \cdot (v_1 x + v_2)^{\frac{-(v_1+v_2)}{2}}$$

Loi positive : Chi-carré divisé par ses degrés de liberté et un chi-carré est toujours positif.

On revient vers une loi normale lorsque les degrés de libertés augmentent.

$$1) F = \frac{\frac{\chi_1^2}{v_1}}{\frac{\chi_2^2}{v_2}} \quad 2) F_{1-\alpha} = t_{1-\frac{\alpha}{2}}^2 \quad 3) t_v = \frac{Z}{\sqrt{\frac{\chi^2}{v}}}$$

4. L'inférence statistique classique

4.1. Les deux théories réciproques

4.1.1. La théorie de l'échantillonnage

μ et σ connus



Population : Lettre grecque
Échantillon : Lettre latine

que dire des différents $\bar{x}$ et s ?

4.1.2. La théorie de l'estimation

Que dire de μ et σ ?



$\bar{x}$ et s d'un échantillon

Deux types d'estimations :

- **L'estimation ponctuelle** : Valeur unique.
- **L'estimation par intervalle de confiance** : Plage de valeurs.

4.2. Les distributions d'échantillonnage

4.2.1. La distribution d'échantillonnage de la moyenne

4.2.1.1. La théorie de l'échantillonnage

Nous avons à chaque fois besoin d'une variable aléatoire dont on connaît la distribution

Permet d'évaluer si un **échantillon** est **représentatif** de sa population.

À ne pas confondre avec la distribution des valeurs (X), la distribution d'échantillonnage de la moyenne est la manière dont se distribue les moyennes des échantillons.

On extrait un échantillon d'une population de moyenne connue et on calcule la moyenne de cet échantillon. Si le résultat est cohérent (compris dans l'intervalle) avec ce que l'on sait de

la population alors pas de problème. Cela va nous permettre de savoir si la différence est significative ou non.

$$L(m_n) = L(\bar{X}) = N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

σ^*

avec : $E(\bar{X}) = \mu$ et $V(\bar{X}) = \frac{\sigma^2}{n}$

$$m_n = \bar{X}$$

$$Z = \frac{\bar{X} - \mu}{\sigma^*}$$

μ et σ connus

$$P(\bar{X} - z_{\alpha/2} * \sigma^* \leq \bar{X} \leq \bar{X} + z_{\alpha/2} * \sigma^*) = 1 - \alpha$$

4.2.1.2. La théorie de l'estimation

C'est une série statistique dans laquelle les valeurs proviennent des valeurs des moyennes des échantillons extraits de la population.

- ➔ Sert à fabriquer des intervalles de confiance (fourchette).
- ➔ Sert à estimer la moyenne d'une population (**μ inconnu**).

$$E(\bar{X}) = \mu$$

1. Si σ est connu :

$$\sigma^* = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}}$$

$$\hat{\mu} = m = \bar{X}$$

Estimation ponctuelle

$$P(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma^*} \leq z_{\alpha/2}) = 1 - \alpha$$

$$Z = \frac{\bar{X} - \mu}{\sigma^*}$$

$$P(\bar{X} - z_{\alpha/2} * \sigma^* \leq \mu \leq \bar{X} + z_{\alpha/2} * \sigma^*) = 1 - \alpha$$

2. Si σ est inconnu et $n > 30$:

$$E(S^2) = \frac{(n-1) \cdot \sigma^2}{n} \neq \sigma^2$$

Attention, sd() renvoi $\hat{\sigma}$!

$$\hat{\sigma}^* = \frac{\hat{\sigma}}{\sqrt{n}}$$

Estimateur biaisé

S^2 est trop petit, il faut un facteur de correction et une estimation convenable

$$\hat{\sigma}^2 = \frac{n}{n-1} s^2$$

$$\hat{\sigma}^* = \frac{s}{\sqrt{n-1}}$$

$$P(\hat{\mu} - z_{\alpha/2} * \frac{s}{\sqrt{n-1}} \leq \mu \leq \hat{\mu} + z_{\alpha/2} * \frac{s}{\sqrt{n-1}}) = 1 - \alpha$$

3. Si σ est inconnu et $n \leq 30$:

$$t = \frac{\bar{X} - \mu}{\hat{\sigma}^*}$$

$$\mu = \bar{X} \cdot t \cdot \frac{s}{\sqrt{n-1}}$$

$$P(\hat{\mu} - t_{\alpha/2;v} * \frac{s}{\sqrt{n-1}} \leq \mu \leq \hat{\mu} + t_{\alpha/2;v} * \frac{s}{\sqrt{n-1}}) = 1 - \alpha$$

Expression générale de l'intervalle de confiance de la moyenne de la population lorsque **σ est inconnu et $n < 30$**

On ne sait pas comment $\bar{X}$ se distribue. On parle de $\bar{X}$ parce qu'on parle de moyenne (estimer la moyenne de la population à partir des moyennes des échantillons).

La **statistique d'un problème** est la variable statistique qui va nous permettre de résoudre le problème.

4.2.2. La distribution d'échantillonnage de la variance

$$\chi^2 = \frac{n * S^2}{\sigma^2}$$

On ne sait pas comme S^2 se distribue. Nous devons de nouveau effectuer un changement de variable.

Suit une loi du chi-carré avec $n-1$ degrés de liberté.

4.3. Les tests d'hypothèse

4.3.1. Les tests d'hypothèse de conformité

Les paramètres H_0 et H_1 proviennent de la population.

Les tests d'hypothèses s'appuient sur la **théorie de l'échantillonnage**. On travaille en supposant que l'on connaît les caractéristiques de la population et on cherche à savoir si l'échantillon donne des valeurs conforme à ce que l'on suppose.

Méthodologie :

On travaille avec l'**hypothèse nulle** : $H_0 : \theta = \theta_0$

Ex : $H_0 : \mu = \mu_0$

- 1) **Si on connaît la distribution d'échantillonnage du paramètre étudié** (V.A. T), il suffit de **déterminer l'intervalle de confiance** (estimé avec un certain niveau de probabilité) des valeurs du paramètre pour les échantillons d'une telle population :
 - Si la valeur t_n appartient à cet intervalle, l'hypothèse nulle est plausible (la population semble bien avoir un paramètre θ ayant la valeur θ_0).
 - Sinon, l'hypothèse nulle est à rejeter et il faut admettre une **hypothèse alternative** qui peut être :
$$H_1 : \theta \neq \theta_0 \quad \text{ou} \quad H_1 : \theta > \theta_0 \quad \text{ou} \quad H_1 : \theta < \theta_0$$
- 2) **Si on ne connaît pas la distribution d'échantillonnage du paramètre étudié**, il faut **opérer un changement de variable approprié sur ce paramètre** (V.A. : $T \rightarrow F(T)$) **afin de disposer d'une loi de distribution** à la forme analytique connue et appliquer la transformation F ainsi définie à toutes les valeurs apparaissant dans l'étude.

Selon le cas, T ou F(T) est alors appelé la "**statistique du test**" ou encore parfois la "**variable de test**".

Dès lors, se demander si t_n appartient à l'intervalle de confiance des valeurs du paramètre des échantillons de la population testée revient à se demander si la valeur transformée $F(t_n)$ appartient à l'intervalle de confiance dont les bornes ont été transformées par F.


Le seuil de signification : Risque de rejeter à tort l'hypothèse nulle alors qu'elle est vraie.

$\alpha = P(\text{rejeter } H_0 \mid H_0 \text{ est vraie}) \rightarrow$ Probabilité de rejeter H_0 alors que pourtant H_0 est vrai. On l'appelle également le **risque de première espèce**.

Son complémentaire $1-\alpha$ est appelé le **niveau de confiance du test**.


Test unilatéral

Une zone d'acceptation de H_0 et une zone de rejet (on répartit le risque d'un seul côté).



Test bilatéral

Deux zones de rejets (on répartit le risque des deux côtés).



Le test est significatif : La différence est significative.

Si on réalise plusieurs tests similaires successifs, on augmente le risque de rejeter H_0 (comme des essais successifs à la **roulette russe** augmentent le risque de voir le coup partir).

Si un tel effet est indésirable, on doit appliquer une correction du seuil de rejet α . Il existe plusieurs techniques, mais celle de **Bonferroni-Holm** est la plus simple : si on réalise n tests, on utilise comme seuil pour chacun d'eux α/n .


nombre de tests n (avec $\alpha = 5\%$)	risque global d'erreur
1	5%
2	10%
10	40%
50	92%
n	$1 - 0.95^n$

La statistique d'un test : Variable aléatoire dont on a besoin de la distribution.

$n-1$ degrés de liberté : Vient de la condition qui porte sur les écarts à la moyenne, **la somme des écarts à la moyenne doit faire 0**. Donc s'ils sont n , les $n-1$ valent ce qu'ils veulent mais le dernier doit combler le trou pour que la somme fasse 0 au total.

p-value : La probabilité que cette variable aléatoire X atteigne et dépasse la valeur x de cette variable pour l'échantillon de test si H_0 est vraie.

$$P\text{-value} = P(X > x | H_0)$$



Si la p-value est très faible (≤ 0.05), il est peu probable que H_0 soit vraie (et donc on le rejettera).

Si au contraire elle est grande (> 0.05), il est probable que H_0 soit fondée (et donc on l'admettra).


Nous pouvons dire que : La p-value est la probabilité de rejet à tort de l'hypothèse nulle (H_0).

4.3.2. Les tests d'hypothèse d'homogénéité

4.3.2.1. De deux échantillons distincts (indépendants)

Il s'agit cette fois de comparer la moyenne, la variance, la proportion, ... de **deux groupes d'individus**, de deux populations. **Nous allons tenter de retomber sur un test qui ressemble à un test de conformité.**

➔ On ne compare plus une valeur aléatoire à une valeur fixe mais deux valeurs aléatoires.



1. Si σ_1 et σ_2 sont connus :

$N(\mu_1 - \mu_2, \sigma_\Delta^*)$ avec

$$\sigma_\Delta^* = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

Les populations sont indépendantes :

$$V(\bar{X}_1 - \bar{X}_2) = V(\bar{X}_1) + V(\bar{X}_2)$$

2. Si σ_1 ou σ_2 sont inconnus :

2.1. Si $n_1 > 30$ et $n_2 > 30$:

$N(\mu_1 - \mu_2, \hat{\sigma}_\Delta^*)$ avec

$$\hat{\sigma}_\Delta^* = \sqrt{\frac{\hat{\sigma}_1^2}{n_1} + \frac{\hat{\sigma}_2^2}{n_2}} = \sqrt{\frac{s_1^2}{n_1 - 1} + \frac{s_2^2}{n_2 - 1}}$$

2.2. Si $n_1 \leq 30$ et $n_2 \leq 30$:

Changement de variable :

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sigma_\Delta^*} \xrightarrow{H_0} St_v$$

On parle des écarts à la moyenne parce qu'on fait intervenir des σ , s , ... et que ses écarts type ou ses variances sont construit sur des écarts à la moyenne. On ne se sait pas comment S^2 se distribue, ce qui nous pousse donc à effectuer un changement de variable. Les lois de La loi de Student et du Loi du chi-carré ou khi-deux dépendent de leurs degrés de liberté (v).

2.2.1. σ_1 supposé = σ_2 :

$$v = (n_1 - 1) + (n_2 - 1)$$

$$v = n_1 + n_2 - 2$$

(Hypothèse d'**homoscédasticité**)

2.2.2. σ_1 supposé $\neq \sigma_2$:

➔ **Test de Welch**

Si on a des degrés de liberté qui ne sont pas entier, cela vient du test de Welch.

$$v = \frac{\left(\frac{\hat{\sigma}_1^2}{n_1} + \frac{\hat{\sigma}_2^2}{n_2}\right)^2}{\frac{\left(\frac{\hat{\sigma}_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{\hat{\sigma}_2^2}{n_2}\right)^2}{n_2 - 1}}$$

(Hypothèse d'**hétéroscédasticité**)

4.3.2.2. De deux échantillons appariés (dépendants)

On considère à présent la même population à deux moments différents.

Appariés : Les valeurs des deux échantillons se correspondent par couples ou par paires.

On étudie donc deux fois la même série statistique. Les valeurs de l'échantillon à ces deux instants différents sont notées :	On considère alors, tout naturellement, les différences :
x_{i_1} et x_{i_2} ($i = 1, \dots, n$)	$d_i = x_{i_2} - x_{i_1}$ ($i = 1, \dots, n$)

Désignons par μ_d et σ_d la moyenne et l'écart-type de la distribution de la variable aléatoire $\bar{D}$.

Notre problème de test d'égalité de deux moyennes se transforme ainsi à nouveau en un test de conformité d'une moyenne, puisque nous allons tester la nullité de la moyenne des écarts entre les membres de chaque paire :

$$H_0 : \mu_1 = \mu_2 \Leftrightarrow \mu_d = 0$$

$$H_1 : \mu_1 < \mu_2 \Leftrightarrow \mu_d > 0$$

1. Si $n_1 > 30$ et $n_2 > 30$:

$$\mu_d = \frac{\sum_{i=1}^n d_i}{n}$$

$$\sigma_d = \frac{s_d}{\sqrt{n}}$$

Une seule variance car il s'agit du même groupe d'individus

2. Si $n_1 \leq 30$ et $n_2 \leq 30$:

Changement de variable :

$$t = \frac{\bar{D} - \mu_d}{\sigma_d}$$

→ se distribue selon une loi de Student avec $n-1$ degrés de liberté

4.3.2.3. De deux variances

$$H_0 : \sigma_1^2 = \sigma_2^2 \Leftrightarrow H_0 : \frac{\sigma_1^2}{\sigma_2^2} = 1$$

à comparer avec

Test de conformité de variances

$$H_0 : \sigma^2 = \sigma_0^2$$

Voir la distribution d'échantillonnage de la variance

Nous passons par une fraction car les – et + avec les carrés ne marchent pas bien.

$$\frac{S_1^2}{S_2^2} \rightarrow \frac{\frac{n_1 \cdot S_1^2}{\sigma_1^2}}{\frac{n_2 \cdot S_2^2}{\sigma_2^2}}$$



$$F = \frac{\frac{n_1 \cdot S_1^2}{v_1 \cdot \sigma_1^2}}{\frac{n_2 \cdot S_2^2}{v_2 \cdot \sigma_2^2}}$$

→ Suit une loi de Fisher avec v_1 et v_2 degrés de liberté.

$$F_{v_1, v_2} = \frac{\frac{n_1 \cdot S_1^2}{(n_1 - 1) \cdot \sigma_1^2}}{\frac{n_2 \cdot S_2^2}{(n_2 - 1) \cdot \sigma_2^2}} = \frac{(\hat{\sigma}_1^2 / \sigma_1^2)}{(\hat{\sigma}_2^2 / \sigma_2^2)} = \frac{S_1^2}{S_2^2} \cdot \frac{n_1 \cdot v_2 \cdot \sigma_2^2}{n_2 \cdot v_1 \cdot \sigma_1^2}$$

4.4. L'analyse de variance à un facteur (ANOVA 1) (Quan~Qual)

Test d'homogénéité de **moyennes** pour plusieurs populations.

On va prendre les écarts des moyennes des échantillons et les comparer avec la moyenne de toutes les données $\bar{x}$, d'où le nom **analyse de la variance** alors qu'il s'agit d'un **test sur les moyennes**.

Il s'agit de comparer les moyennes de plusieurs populations supposées normales et de même variance à partir d'**échantillons aléatoires indépendants** : on compare un certain nombre p d'échantillons, ce qui définit p variables aléatoires $X_1, X_2, \dots, X_p$.

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \dots = \mu_p$$

H_1 : Il existe une différence significative entre les échantillons, imputable à un (ou plusieurs) facteur(s) explicatif(s) que l'on appelle **facteur(s) de contrôle**.

Si l'on désigne par M la variable aléatoire prenant comme valeur les différentes moyennes, on peut écrire l'hypothèse testée H_0 sous la forme :

$$H_0 : \sigma_M = 0$$

Si on s'intéresse aux sources de variation de toutes les valeurs par rapport à leur moyenne générale, on peut considérer, si :

Moyenne de l'échantillon i : $\bar{x}_i = \frac{\sum_{j=1}^{n_i} x_{ij}}{n_i}$ et Moyenne de toutes les données : $\bar{x} = \frac{\sum_{i=1}^p n_i \bar{x}_i}{n} = \frac{\sum_{i=1}^p \sum_{j=1}^{n_i} x_{ij}}{\sum_{i=1}^p n_i}$

i : Numéro de l'échantillon
 j : Indice dans l'échantillon

1) **La variance résiduelle** : L'estimation de la variation se fait ici à partir des variances **intra-classes** ou **carrés moyens résiduels**. On se préoccupe donc ici des **variations dues aux fluctuations d'échantillonnage**, c'est-à-dire des différences normales entre les valeurs observées dans un échantillon et leur moyenne. Chaque groupe a un degré de liberté de $n_i - 1$.

$$(x_{ij} - \bar{x}_i)$$

2) **La variance factorielle** : L'estimation de la variation se fait ici à partir des variances **inter-classes**. Nous allons donc cette fois **mesurer les différences entre les groupes**. On va considérer que les valeurs de chaque groupe forment en fait les valeurs d'un seul échantillon. On peut ainsi calculer une moyenne m générale. On calcule alors la variance estimée correspondante mais où toutes les valeurs d'un groupe sont remplacées par leur moyenne, avec par conséquent $p - 1$ comme nombre de degrés de liberté.

$$(\bar{x}_i - \bar{x})$$

$$x_{ij} - \bar{x} = (x_{ij} - \bar{x}_i) + (\bar{x}_i - \bar{x})$$

$$\sum_{i=1}^p \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2 = \sum_{i=1}^p \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2 + \sum_{i=1}^p \sum_{j=1}^{n_i} (\bar{x}_i - \bar{x})^2$$

$$\sum_{i=1}^p \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2 = \sum_{i=1}^p \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2 + \sum_{i=1}^p n_i * (\bar{x}_i - \bar{x})^2$$

SCE totale = SCE résiduelle + SCE factorielle

p : Nombre d'échantillon.

n : Nombre total de valeurs que l'on trouve dans les différents échantillons.

$$\hat{\sigma}_r^2 = \frac{SCE_r}{n-p} = CM_r$$

$$\hat{\sigma}_f^2 = \frac{SCE_f}{p-1} = CM_f$$

Carrés moyens

$$F = \frac{\frac{SCE_f}{p-1}}{\frac{SCE_r}{n-p}} \quad F = \frac{CM_f}{CM_r} \quad F = \frac{\hat{\sigma}_f^2}{\hat{\sigma}_r^2}$$

→ Doit suivre une loi de Fisher de degrés de liberté p-1 et n-1.

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}} = \frac{SCE}{n}$$

$$\hat{\sigma} = \sqrt{\frac{n}{n-1}} s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$$

$$\Rightarrow \hat{\sigma} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{v}}$$

$$\Rightarrow \hat{\sigma}^2 = \frac{SCE}{v}$$

Si F = 16.73, v1 = 3 et v2 = 20, nous pouvons calculer la p-value comme cela :

```
> pf(16.74, 3, 20, lower.tail=F)
[1] 1.118887e-05
```

→ Utilisation de *lower.tail = F* vu que la probabilité est celle d'être plus grande ou égale.

pf() donne une probabilité sur base d'un quantile.

oneway.test() permet de définir les variances comme étant inégale (test d'hétéroscédasticité).

pairwise.test() permet d'effectuer la comparaison de chaque population une à une en passant en vue tous les cas possibles.

4.5. L'analyse statistique à deux dimensions (Régression-corrélation) (Quan~Quan)

4.5.1. Statistique descriptive

Modèle mathématique = formule

Pente/coefficient angulaire


Fonction : Fonction du premier degré ($y = ax + b$).

Résidu (d, e ou r) : Ecart entre la valeur observée et la valeur prédire par le modèle.

Courbe d'ajustement ou courbe de régression :


Parmi toutes les courbes qui ajustent un ensemble de données, la meilleure, c'est-à-dire celle qui réalise le meilleur ajustement, c'est celle pour laquelle la quantité :

$$d_1^2 + d_2^2 + \dots + d_n^2 = \sum_{i=1}^n d_i^2 \quad \text{est minimum}$$



Traitement statistique des données

Nous devons passer par les **dérivées** pour calculer la valeur minimale d'une fonction.



$$a = \frac{\sum_{i=1}^n x_i * y_i - \bar{x} * \sum_{i=1}^n y_i}{\sum_{i=1}^n x_i^2 - \bar{x} * \sum_{i=1}^n x_i} = \frac{\sum_{i=1}^n X_i * Y_i}{\sum_{i=1}^n X_i^2}$$

$$b = \bar{y} - a * \bar{x}$$

Equation du premier degré :

Nous pouvons trouver les valeurs de a et b à l'aide d'un système d'équation à 2 inconnues

La courbe obtenue est appelée la **courbe des moindres carrés**. On parle encore aussi de la courbe de **régression** de y en x.

La droite des moindres carrés :

Le coefficient a est encore appelé le "**coefficient de régression**", par ce qu'il est le plus important.

$$X_i = x_i - \bar{x} \quad \text{et} \quad Y_i = y_i - \bar{y}$$

$$y_{\text{iest}} = \hat{y}_i = ax_i + b \quad \leftarrow \text{le modèle prédictif}$$

$$y_i = ax_i + b + d_i = ax_i + b + e_i \quad \leftarrow \text{le modèle théorique}$$

La variance résiduelle :

Variation/erreur

Nous pouvons toujours calculer la courbe d'ajustement mais cela ne suffit pas, nous devons à présent se demander dans quelle mesure son emploi est justifié :

$$\begin{array}{|c|c|c|} \hline \text{variation totale} & \text{variation résiduelle} & \text{variation expliquée} \\ \hline \Rightarrow & y_i - \bar{y} = (y_i - y_{\text{iest}}) + (y_{\text{iest}} - \bar{y}) & \\ \hline \end{array}$$

Fais intervenir le modèle alors qu'on se focalise uniquement sur les petits écarts

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - y_{\text{iest}})^2 + \sum_{i=1}^n (y_{\text{iest}} - \bar{y})^2$$

$$\text{SCE totale} = \text{SCE résiduelle} + \text{SCE expliquée}$$

Le double produit disparaît vu que la somme des écarts à la moyenne vaut 0.

R va traiter le problème de l'ANOVA et le problème de la régression corrélation avec la même formule (lm).

Variance
résiduelle :

$$s_r^2 = \frac{\sum_{i=1}^n (y_i - y_{\text{iest}})^2}{n}$$

Variance
expliquée :

$$s_e^2 = \frac{\sum_{i=1}^n (y_{\text{iest}} - \bar{y})^2}{n}$$

$$s_y^2 = s_r^2 + s_e^2$$

Coefficient de corrélation :

$$r = \pm \sqrt{\frac{\text{variation expliquée}}{\text{variation totale}}} = \pm \sqrt{\frac{\sum_{i=1}^n (y_{\text{iest}} - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}} = \pm \sqrt{\frac{\sum_{i=1}^n (y_{\text{iest}} - \bar{y})^2}{\sum_{i=1}^n (y_i - y_{\text{iest}})^2 + \sum_{i=1}^n (y_{\text{iest}} - \bar{y})^2}}$$

$$r \in [-1; +1]$$

Le coefficient de corrélation va permettre de quantifier le fait qu'utiliser la droite de régression est une bonne idée ou pas.

Dans le cas d'un ajustement parfait, la variation résiduelle est nulle, si bien que la variation totale se résume à la variation expliquée.

r vaut donc +/-1, le signe indiquant dans quel sens la corrélation se fait.

Dans le cas de l'absence d'ajustement, la variation totale provient de la variation résiduelle, qui est alors beaucoup plus grande que la variation expliquée (on se retrouve à une valeur divisée par la même valeur + une très grande valeur).

r est alors proche de 0.

Coefficient de corrélation linéaire ou coefficient de Pearson :

Dans le cas où la relation unissant les deux variables est linéaire :


$$y_{\text{iest}} = a_0 + a_1 x_i$$

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$


$$r = \frac{\text{cov}(X, Y)}{s_x * s_y} = \frac{s_{xy}}{s_x * s_y}$$

$$s_{xy} = \text{cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x}) * (y_i - \bar{y})}{n} = \frac{\sum_{i=1}^n X_i * Y_i}{n} - \bar{x} * \bar{y}$$

Si s_{xy} est positif ou négatif, la relation unissant les deux variables est croissante ou décroissante.



Si deux variables sont indépendantes, leur covariance (s_{xy}) est nulle, mais la réciproque n'est pas toujours vraie.



Si les deux variables sont indépendantes, alors le coefficient de corrélation (et aussi la covariance) vaut 0. **Mais si le coefficient de corrélation linéaire est nul, les deux variables ne sont pas obligatoirement indépendantes.** Simplement, il n'y a pas de corrélation linéaire !

4.5.2. Inférence statistique

Coefficient de corrélation :

Variable aléatoire R → estimation de ρ

Estimation ponctuelle : $\hat{\rho} = r$

Nous ne savons pas comment R se distribue.

1. $H_0 : \rho = 0$ (test d'absence de corrélation)

La courbe de la distribution d'échantillonnage de R n'est symétrique que si $\rho=0$.

Nous allons donc effectuer un changement de variable :

$$t = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}}$$

→ Suit une loi de Student avec n-2 degrés de liberté.

2. $H_0 : \rho = \rho_0 \rightarrow N > 25$ (test d'un niveau de corrélation)

Transformation de Fisher ou z-transformation :

Nous effectuons de nouveau un changement de variable :

$$Z = \frac{1}{2} * \ln \frac{1+R}{1-R}$$

→ Suit une loi normale $N(\mu, \sigma)$

$$\mu \approx \frac{1}{2} * \ln \frac{1+\rho}{1-\rho} \quad \sigma \approx \frac{1}{\sqrt{n-3}}$$

Attention, il ne s'agit pas du Z de la centrée réduite !
Dans le cas particulier de la corrélation, il s'agit d'une deuxième variable aléatoire

Coefficient de corrélation :

$$\begin{aligned} y_{\text{test}} &= ax_i + b \\ y_i &= ax_i + b + d_i \end{aligned}$$



$$\begin{aligned} y_i &= \alpha x_i + \beta + d_i \\ \text{ou} \\ Y &= \alpha X + \beta + D \end{aligned}$$

$$\hat{\alpha} = a \quad \text{et} \quad \hat{\beta} = b$$

$$H_0 : \alpha = \alpha_0$$

$$N(\alpha, \sigma_A^*)$$

$$\hat{\sigma}_A^* = \sqrt{\frac{(1-r^2) * s_y^2}{(n-2) * s_x^2}} = \sqrt{\frac{s_y^2 - \frac{s_{xy}^2}{s_x^2}}{(n-2) * s_x^2}}$$

$$t = \frac{A - \alpha}{\hat{\sigma}_A^*}$$

→ Suit une loi de Student avec n-2 degrés de liberté.

Il y a les contraintes des écarts à la moyenne en x et en y ce qui fait 2 contraintes (n-2)

$$H_0 : \beta = \beta_0 \rightarrow \text{Idem que pour } \alpha$$

$$L(A) = N(\alpha, \sigma_A^*) \quad \text{et} \quad L(B) = N(\beta, \sigma_B^*)$$

Les variables aléatoires A et B suivent tous les deux des lois normales mais moches donc R préfère que l'on travaille avec la variable centrée et réduite qui conduit à des Student :

$$t = \frac{A - \alpha}{\hat{\sigma}_A^*} \rightarrow St_{n-2} \quad \text{où} \quad \hat{\sigma}_A^* = \sqrt{\frac{(1-r^2) * s_y^2}{(n-2) * s_x^2}} = \sqrt{\frac{s_y^2 - \frac{s_{xy}^2}{s_x^2}}{(n-2) * s_x^2}}$$

$$t = \frac{B - \beta}{\hat{\sigma}_B^*} \rightarrow St_{n-2} \quad \text{où} \quad \hat{\sigma}_B^* = \sqrt{\frac{(1-r^2) * s_y^2}{(n-2) * s_x^2} * (s_x^2 + \bar{x}^2)}$$

Modèle au niveau de la population :

$$\hat{\alpha} = a \quad \text{et} \quad \hat{\beta} = b$$

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$y_i = \alpha x_i + \beta + \varepsilon_i$$

y_i sont les valeurs de la variable **expliquée** (quantitative)

x_i sont les variables de la variable **explicative** (quantitative)

Du côté de R :

Coefficients:				
$b \rightarrow \beta_0$	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	182.775	18.160	10.065	1.67e-07 ***
vision	-30.750	4.898	-6.277	2.84e-05 ***
$a \rightarrow \beta_1$				

Pour chaque ligne R fait un test d'hypothèse en se posant la question si $H_0 : \beta_i = 0$ (test de conformité).

Il fait un test de Fisher en plus :

F-statistic: 39.41 on 1 and 13 DF, p-value: **2.845e-05**

Compare le modèle calculé avec le modèle complet où on enlève tout sauf H_0 . On se retrouve avec $H_0 : \beta_1 = 0$ du coup logique que l'on tombe sur la même valeur que plus haut. Dans l'état actuel des choses cela ne sert à rien mais plusieurs valeurs interviendront en bloc 3.

Si on a une grosse p-value pour β_0 cela veut dire que le modèle de régression n'a pas de terme indépendant.

Intervalle de confiance d'une valeur calculée à partir de la formule de régression :

Les deux coefficients ne sont pas connus avec certitude :

$$L(\hat{Y}_i) = ? \quad t = \frac{\hat{Y}_i - (\hat{\alpha} * x_i + \hat{\beta})}{\hat{\sigma}_i^*} \rightarrow St_{n-2} \quad \text{où} \quad \hat{\sigma}_i^* = \sqrt{\frac{(1-r^2) * s_y^2}{(n-2) * s_x^2} * ((n+1) * s_x^2 + (x_i - \bar{x})^2)}$$

Traitement statistique des données → Suit une loi de Student avec $n-2$ degrés de liberté. 20

4.6. Le test du chi-carré (Qual~Qual)

L'origine du chi-carré = vérifier si une distribution d'effectifs est en accord avec les probabilités correspondantes.

$$\chi^2 = \sum_{i=1}^2 \frac{(\text{effectifs observés} - \text{effectifs prédits})^2}{\text{effectifs prédits}}$$

Les résultats obtenus pour l'échantillon consulté seront présentés dans un tableau à double entrée que l'on appelle un **tableau de contingence** (effectifs observés) :

		Salaires			
		Modeste	Moyenne	Grasse	
Satisfaction	3	13	19	25	57
	2	28	29	28	85
	1	24	18	16	58
		65	66	69	200

$n_{ij} = n_{11}$ (pointing to cell 1,1)
Marges horizontales : $n_j = \sum_{i=1}^p n_{ij}$
Marges verticales : $n_i = \sum_{j=1}^q n_{ij}$
 $n = n_{..} = \sum_{j=1}^q n_{.j} = \sum_{i=1}^p n_{i.} = \sum_{i=1}^p \sum_{j=1}^q n_{ij}$
p : Nombre de lignes
q : Nombre de colonne

Nous allons tester ne hypothèse H_0 supposant que les deux caractères sont indépendants.

Pour pouvoir tester de la validité de notre hypothèse, il nous faut disposer des **effectifs théoriquement prévisibles** s'il en est bien ainsi.

Il faut calculer les probabilités (**probabilités conjointes**) associées à chaque paire de valeurs des deux caractères en tenant compte :

- des observations de l'échantillon
- et de l'indépendance testée.

- 1) Tout d'abord : déterminer les probabilités associées à chaque valeur de chaque caractère, sans se soucier de l'autre. Il s'agira simplement des valeurs obtenues à partir fréquences issues des observations = **les effectifs marginaux divisés par l'effectif total**.

Ex : Satisfaction3 est : $p_{1.} = 57/200 = 0.285$

- 2) **Probabilités conjointes** = probabilités associées à chaque paire de valeurs des deux caractères **en tenant compte** des observations de l'échantillon et **de l'indépendance testée**, c'est-à-dire qu'on considère que :

$$H_0 : p_{ij} = p_{i.} * p_{.j} \quad (i = 1, \dots, p \text{ et } j = 1, \dots, q)$$

Lorsque deux événements sont **indépendants**, la probabilité que ses 2 événements se produisent c'est le **produit de probabilité** (Ex : Première urne autant de bleu et de rouge, deuxième urne autant de bleu et de rouge et donc tirer une boule de la

0000	
25	57
28	86
16	58
69	200

première urne et tirer une boule de la deuxième sont deux choses indépendantes. La probabilité de tirer une bleu dans la première et une rouge dans la deuxième est le produit de la probabilité de tirer une bleu dans la première urne multiplié par la probabilité de tirer une rouge dans la deuxième urne. S'il n'y avait qu'une seule urne, les événements seraient dépendants).

$$H_0 : p_{ij} = p_{i.} * p_{.j}$$

$$P_{11} = 0,352 * 0,285$$

$$P_{11} = 0,092625$$

		Salaires			
		<30000	<80000	>=80000	$p_{i.}$
Satisfaction	3	0,092625	0,09405	0,098325	0,285
	2	0,138125	0,14025	0,146625	0,425
	1	0,09425	0,0957	0,10005	0,29
$p_{.j}$		0,325	0,33	0,345	1

3) Effectifs théoriques t_{ij} : en multipliant chacune des probabilités p_{ij} calculées ci-dessus par l'effectif total.

$$t_{ij} = n * p_{ij}$$

$$t_{11} = 200 * 0,092625$$

$$t_{11} = 18,525$$

		Salaires			
		<30000	<80000	>=80000	$t_{i.}$
Satisfaction	3	18,525	18,81	19,665	57
	2	27,625	28,05	29,325	85
	1	18,85	19,14	20,01	58
$t_{.j}$		65	66	69	200

Dans quelle mesure ces effectifs théoriques t_{ij} sont-ils en accord avec les effectifs observés n_{ij} ?

4) On peut donc démontrer que, sous l'hypothèse H_0 , la statistique :

$$\chi^2 = \sum_{i=1}^p \sum_{j=1}^q \frac{(n_{ij} - t_{ij})^2}{t_{ij}}$$

Suit une loi du chi-carré, pour peu que les effectifs théoriques soient au moins 5 par valeur (ou par classe) - s'il n'en est pas ainsi, on regroupe des classes adjacentes.

Degrés de libertés :

- Pour chaque colonne, on peut fixer $(p-1)$ valeurs $p_{i.}$, la dernière vaut 1 – leur somme.
- Pour chaque ligne, on peut fixer $(q-1)$ valeur $p_{.j}$, puisque la dernière vaut 1 – leur somme.

Donc :

$$v = (p-1) * (q-1)$$