

CHAPITRE 1

I. Le Monde des Big Data, du Data Mining et du Machine Learning

- **Big Data :**
 - Définition : Masse immense et informe de données à manipuler et à analyser.
 - Caractéristiques : Volume important, variété des types de données, vélocité (rapidité de création et de traitement), véracité (fiabilité des données).
 - Techniques : Méthodes pour transformer ces données brutes en informations structurées, exploitables et valorisables.
 - Exemples : Données générées sur Internet, données collectées par les entreprises (Google, Amazon), données issues de mesures, enquêtes, etc.
- **Data Mining (Exploration de données) :**
 - Définition : Processus d'extraction de connaissances (patterns, tendances) à partir de grandes quantités de données.
 - Objectif : Découvrir des informations utiles pour la prise de décision, la prédiction, etc.
- **Machine Learning (Apprentissage automatique) :**
 - Définition : Ensemble de méthodes permettant à un ordinateur d'apprendre à partir de données, sans être explicitement programmé pour chaque tâche.
 - Objectif : Construire des modèles prédictifs, des systèmes de recommandation, etc.

II. Techniques et Outils

- **Techniques Statistiques pour “faire parler les données” :**
 - Régression-Corrélation : Étudier la relation entre deux variables quantitatives.
 - Analyse de Variance (ANOVA) : Comparer les moyennes de groupes définis par une variable qualitative.
 - Test du Chi-Carré : Étudier la relation entre deux variables qualitatives.
 - Régression Logistique : Modéliser la probabilité d'un événement en fonction de variables explicatives.
- **Plateformes de Data Mining :**
 - SAS (logiciel commercial).
 - R (logiciel open source).

III. Concepts Clés

- **Variables :**
 - Variable Expliquée (dépendante) : La variable que l'on cherche à expliquer ou prédire.
 - Variable Explicative (indépendante) : La variable utilisée pour expliquer ou prédire la variable expliquée.
 - Types de Variables :
 - Quantitative : Mesure une quantité (ex : taille, poids, revenu).
 - Qualitative : Décrit une qualité ou une catégorie (ex : couleur, genre, opinion).
- **Modèle :**

- Représentation simplifiée de la réalité, utilisée pour comprendre, expliquer ou prédire un phénomène.
- **Data Warehouse (Entrepôt de données) :**
 - Système de stockage centralisé de données, optimisé pour l'analyse et le reporting.

Conseils pour ta préparation théorique :

- **Comprendre les définitions :** Assure-toi de bien comprendre les définitions de Big Data, Data Mining et Machine Learning.
- **Identifier les objectifs :** Quel est le but du Data Mining et du Machine Learning ?
- **Connaître les techniques statistiques :** Comment les différentes techniques statistiques peuvent-elles être utilisées pour analyser les données ?
- **Se familiariser avec les outils :** Qu'est-ce que SAS et R ?
- **Comprendre les types de variables :** Quelle est la différence entre une variable quantitative et une variable qualitative ?
- **Visualiser le processus :** Comment les données brutes sont-elles transformées en informations exploitables ?

CHAPITRE 2

1. Le problème général

- **Population** : L'ensemble complet des objets ou des personnes que l'on souhaite étudier.
- **Échantillon** : Un sous-ensemble de la population, utilisé pour faire des inférences sur la population entière.
- **Caractère (ou variable)** : La caractéristique de la population que l'on étudie.
 - **Quantitatif** : Mesurable (représentable par un nombre).
 - **Qualitatif** : Non mesurable numériquement.

2. Les variables statistiques

- **Variable statistique discrète** :
 - Définition : Chaque valeur possible est isolée de ses voisines.
 - Exemple : Nombre d'animaux domestiques dans une famille.
 - Notation :
 - : Les différentes valeurs possibles de la variable.
 - : Le nombre de fois que la valeur est observée (effectif).
 - : Le nombre total d'éléments dans l'échantillon.
 - : Nombre de valeurs possibles.
- **Variable statistique continue** :
 - Définition : Peut prendre n'importe quelle valeur dans un intervalle donné.
 - Exemple : Salaire hebdomadaire des employés.
 - Groupement en classes : Les valeurs sont regroupées en intervalles .
 - Centre de classe : Le milieu de l'intervalle, noté .
 - Effectif partiel : Le nombre d'observations dans chaque classe, noté .

3. Étude synthétique d'un caractère quantitatif

- **Objectif** : Résumer et décrire les données de manière significative.
- **Approches** :
 - **Graphique** :
 - Variable discrète : Diagramme en bâtons, polygone des effectifs cumulés, diagramme sectoriel.
 - Variable continue : Histogramme, polygone des fréquences, polygone des effectifs cumulés, diagramme sectoriel.
 - **Calculée** : Déterminer des paramètres représentatifs.

4. Paramètres de tendance centrale

- **Moyenne arithmétique** : La somme des valeurs divisée par le nombre total de valeurs.
- **Médiane** : La valeur qui divise la série statistique ordonnée en deux parties égales.
- **Mode** : La valeur qui apparaît le plus fréquemment.
- **Moyenne géométrique** : Utilisée pour les distributions à longue traîne.
- **Moyenne pondérée** : Moyenne tenant compte de l'importance relative de chaque valeur.

5. Paramètres de dispersion

- **Écart moyen absolu** : La moyenne des valeurs absolues des écarts à la moyenne.
- **Variance** : La moyenne des carrés des écarts à la moyenne.
- **Écart-type** : La racine carrée de la variance.

- **Coefficient de variation** : Mesure la dispersion relative des données par rapport à la moyenne.
- **Quantiles** : Valeurs qui divisent la série statistique ordonnée en parties égales (quartiles, déciles, centiles).
- **Étendue** : L'écart entre le minimum et le maximum de la série statistique.

6. Forme de la courbe de distribution

- **Coefficient de dissymétrie (Skewness)** : Mesure l'asymétrie de la distribution.
 - $Sk = 0$: Courbe symétrique.
 - $Sk > 0$: Courbe déplacée vers la gauche (asymétrie positive).
 - $Sk < 0$: Courbe déplacée vers la droite (asymétrie négative).
- **Coefficient d'aplatissement (Kurtosis)** : Mesure le degré d'aplatissement de la courbe.
 - $\alpha_4 = 3$: Courbe normale (mésokurtique).
 - $\alpha_4 > 3$: Courbe aigüe (leptokurtique).
 - $\alpha_4 < 3$: Courbe aplatie (platykurtique).

7. Variable aléatoire discrète

- **Loi de probabilité** : Associe à chaque valeur possible de la variable une probabilité d'observation.
- **Fonction de répartition** : Donne la probabilité d'observer une valeur inférieure ou égale à une valeur donnée.
- **Espérance mathématique** : La valeur moyenne limite obtenue quand le nombre d'observations devient grand (tend vers l'infini).
- **Écart-type (ou variance)** : Mesure la dispersion des valeurs autour de l'espérance mathématique.

8. Variable aléatoire continue

- **Densité de probabilité** : Une fonction dont l'intégrale sur un intervalle donne la probabilité que la variable aléatoire prenne une valeur dans cet intervalle.
- **Fonction de répartition** : Donne la probabilité d'observer une valeur inférieure ou égale à une valeur donnée.
- **Espérance mathématique** : La valeur moyenne limite obtenue quand le nombre d'observations devient grand (tend vers l'infini).
- **Écart-type (ou variance)** : Mesure la dispersion des valeurs autour de l'espérance mathématique.

Conseils pour ta préparation théorique :

- **Bien comprendre la différence entre statistique descriptive et inférence statistique.**
- **Savoir distinguer les variables quantitatives des variables qualitatives.**
- **Connaître les différentes mesures de tendance centrale et de dispersion, et savoir quand les utiliser.**
- **Comprendre la notion de loi de probabilité pour les variables discrètes et de densité de probabilité pour les variables continues.**
- **Faire la différence entre variable statistique et variable aléatoire.**

CHAPITRE 4

1. Loïs de distribution statistiques continues

- **Loi Normale (ou Loi de Gauss ou Loi de Laplace-Gauss)**
 - Définition et propriétés : courbe en forme de cloche, symétrie, dépendance de la moyenne (μ) et de l'écart-type (σ).
 - Loi normale générale et loi normale centrée réduite ($N(0;1)$).
 - Transformation d'une loi normale générale en loi normale centrée réduite ($Z = (X - \mu) / \sigma$).
 - Utilisation des tables de la loi normale centrée réduite pour calculer des probabilités.
 - Fonctions R : `pnorm()`, `qnorm()`, `rnorm()`, `dnorm()`.
- **Loi de Student**
 - Définition : distribution symétrique autour de l'origine, plus aplatie que la loi normale centrée réduite.
 - Paramètre : nombre de degrés de liberté (v).
 - Relation avec la loi normale : approximation de la loi normale centrée réduite lorsque le nombre de degrés de liberté augmente.
 - Fonctions R : `pt()`, `qt()`, `rt()`, `dt()`.
- **Loi du Chi-carré (χ^2)**
 - Définition : somme des carrés de variables aléatoires normales centrées réduites.
 - Paramètre : nombre de degrés de liberté (v).
 - Propriétés : variable aléatoire positive, distribution asymétrique, relation avec la loi normale (approximation lorsque le nombre de degrés de liberté augmente).
 - Additivité : la somme de deux variables aléatoires indépendantes suivant la loi du chi-deux suit également une loi du chi-deux.
- **Loi de Fisher-Snedecor**
 - Définition et paramètres (v_1, v_2).
 - Relation avec les autres lois : lien avec la loi de Student et la loi du chi-carré.

2. Concepts clés à maîtriser

- **Variables aléatoires**
 - Définition et types (continues, discrètes).
- **Distributions de probabilité**
 - Définition et propriétés.
 - Fonction de densité de probabilité ($f(x)$).
 - Fonction de répartition.
- **Paramètres statistiques**
 - Moyenne (μ) : mesure de la tendance centrale.
 - Écart-type (σ) : mesure de la dispersion.
 - Degrés de liberté (v) : nombre de valeurs indépendantes dans un calcul statistique.
- **Théorèmes importants**
 - Théorème central limite : convergence vers la loi normale.

3. Utilisation du logiciel R

- Fonctions statistiques de base :
 - `pnorm()` : calcule la fonction de répartition de la loi normale.
 - `qnorm()` : calcule les quantiles de la loi normale.
 - `rnorm()` : génère des nombres aléatoires suivant la loi normale.
 - `dnorm()` : calcule la densité de probabilité de la loi normale.
 - `pt()`, `qt()`, `rt()`, `dt()` : fonctions équivalentes pour la loi de Student.

Conseils pour ta préparation théorique :

- **Relis attentivement les définitions** des lois de distribution et des concepts clés.
- **Assure-toi de comprendre les propriétés** de chaque loi (symétrie, paramètres, etc.).
- **Fais des liens entre les différentes lois.**
- **Familiarise-toi avec les fonctions R** mentionnées.
- **Si possible, essaie de trouver des exemples concrets** d'application de ces lois dans des domaines tels que la biologie, l'économie ou la physique.

CHAPITRE 5

1. Les deux théories réciproques : l'échantillonnage et l'estimation

- **Échantillonnage :**

- Définition : Processus de sélection d'un sous-ensemble (échantillon) d'une population pour en déduire des informations sur l'ensemble de la population.
- Techniques d'échantillonnage : Méthodes pour garantir que l'échantillon est représentatif de la population (par exemple, échantillonnage aléatoire).

- **Estimation :**

- Définition : Processus d'estimation des paramètres (par exemple, la moyenne, la variance) d'une population à partir des données d'un échantillon.
- Types d'estimation :
 - Estimation ponctuelle : Donner une valeur unique comme estimation du paramètre.
 - Estimation par intervalle de confiance : Donner une plage de valeurs dans laquelle le paramètre est susceptible de se trouver, avec un certain niveau de confiance.

2. Les distributions d'échantillonnage

- Définition : La distribution des valeurs d'une statistique (par exemple, la moyenne) calculée à partir de plusieurs échantillons prélevés dans la même population.
- Importance : Essentielle pour l'inférence statistique, car elle permet de déterminer la probabilité d'observer une certaine valeur de la statistique si l'hypothèse sur la population est vraie.
- Distribution d'échantillonnage de la moyenne : Distribution des moyennes de tous les échantillons possibles de même taille prélevés dans une population.

3. Distribution d'échantillonnage de la moyenne

- Théorème central limite : Un résultat fondamental qui stipule que la distribution d'échantillonnage de la moyenne se rapproche d'une loi normale lorsque la taille de l'échantillon est suffisamment grande (généralement $n \geq 30$), quelle que soit la distribution de la population d'origine.
- Forme de la distribution d'échantillonnage : Normale, avec une moyenne égale à la moyenne de la population et un écart-type égal à l'écart-type de la population divisé par la racine carrée de la taille de l'échantillon.
- Utilisation : Permet d'évaluer si un échantillon est représentatif de sa population.

4. L'estimation

- Estimateur : Une statistique utilisée pour estimer un paramètre de la population.
- Estimateur sans biais : Un estimateur dont la moyenne de sa distribution d'échantillonnage est égale à la vraie valeur du paramètre.
- Estimation ponctuelle de la moyenne : La moyenne de l'échantillon est utilisée comme estimation de la moyenne de la population.

- Estimation de la moyenne par intervalle de confiance : Déterminer une plage de valeurs dans laquelle la moyenne de la population est susceptible de se trouver, avec un certain niveau de confiance.
- Intervalle de confiance : Une plage de valeurs calculée à partir des données de l'échantillon, qui a une certaine probabilité de contenir la vraie valeur du paramètre de la population.
- Niveau de confiance : La probabilité que l'intervalle de confiance contienne la vraie valeur du paramètre (par exemple, 95%).
- Facteurs influençant la largeur de l'intervalle de confiance :
 - Niveau de confiance : Plus le niveau de confiance est élevé, plus l'intervalle est large.
 - Taille de l'échantillon : Plus la taille de l'échantillon est grande, plus l'intervalle est étroit.
 - Écart-type de la population : Plus l'écart-type de la population est grand, plus l'intervalle est large.
- Estimation ponctuelle de la variance :
- Distribution d'échantillonnage de la variance
- Loi de Student : Utilisée pour construire des intervalles de confiance lorsque l'écart-type de la population est inconnu et que la taille de l'échantillon est petite ($n < 30$).

Conseils pour ta préparation théorique :

- **Bien comprendre les définitions** des concepts clés (échantillonnage, estimation, intervalle de confiance, etc.).
- **Comprendre le rôle des distributions d'échantillonnage** dans l'inférence statistique.
- **Connaître les conditions d'application du théorème central limite.**
- **Savoir comment construire un intervalle de confiance** pour la moyenne d'une population, en fonction de la taille de l'échantillon, de l'écart-type de la population (connu ou inconnu) et du niveau de confiance souhaité.
- **Comprendre la différence entre l'utilisation de la loi normale et de la loi de Student** pour construire des intervalles de confiance.
- **Se familiariser avec les formules** utilisées pour calculer les intervalles de confiance.