

Synthèse des Manipulations de Données sous R

Ce document présente une synthèse des principales fonctions et techniques R utilisées dans les travaux pratiques de statistiques. Pour chaque section, vous trouverez une description des fonctions, leur syntaxe et des exemples d'utilisation.

ASTUCE:

Ce document utilise un code couleur pour faciliter la lecture : les titres de chapitres sont en bleu, les sections en vert, et les fonctions en violet.

TP1 - Manipulation des Données

A. Récupération et mise en forme des données

`read.table()`, `read.csv()`

Fonctions permettant de charger des données depuis un fichier.

```
ozone <- read.table(file.choose())
donnees <- read.csv("fichier.csv")
```

`View()`

Affiche le tableau de données dans une interface similaire à Excel.

```
View(ozone)
```

NOTE:

La fonction `View()` est très utile pour explorer rapidement vos données, mais elle n'est pas disponible dans les scripts exécutés en mode batch.

`nrow()`, `ncol()`

Retournent respectivement le nombre de lignes et de colonnes d'un tableau.

```
nrow(ozone) # nombre d'observations
ncol(ozone) # nombre de variables
```

`rownames()`, `colnames()`

Affichent les noms des lignes et des colonnes du tableau.

```
rownames(ozone)  
colnames(ozone)
```

str()

Affiche la structure du tableau : types de variables, aperçu des données.

```
str(ozone)
```

B. Accès aux données

Accès aux colonnes

Trois méthodes principales pour accéder aux colonnes d'un tableau.

```
colonne3_1 <- ozone[, 3]      # Par position
colonne3_2 <- ozone$T12      # Par nom via $
colonne3_3 <- ozone[['T12']]  # Par nom via [[ ]]
```

ASTUCE:

L'accès par nom avec \$ est la méthode la plus lisible et la plus couramment utilisée, mais elle ne fonctionne pas si le nom de colonne contient des espaces ou des caractères spéciaux.

C. Manipulations des données

Renommer une colonne

Modification du nom d'une colonne dans un tableau.

```
names(ozone)[names(ozone) == "pluie"] <- "Pluies"
```

Filtrage par condition

Sélection des lignes qui satisfont une condition.

```
ozone_85 <- ozone[ozone$maxO3 >= 85, ]
```

Filtrage par texte

Sélection des lignes selon une condition textuelle.

```
ozone_sec <- ozone[tolower(ozone$Pluies) == "sec", ]
```

Filtrage par conditions multiples

Combinaison de plusieurs conditions avec les opérateurs logiques.

```
ozone_sec_95 <- ozone[tolower(ozone$Pluies) == "sec" & ozone$maxO3 >= 95, ]
```

Recodage de variables

Transformation des valeurs d'une variable selon une condition.

```
ozone$pluie <- ifelse(tolower(ozone$Pluies) == "sec", "Oui", "Non")
```

Extraction de variables par type

Sélection des colonnes selon leur type (numériques, facteurs...).

```
ozone_quanti <- ozone[sapply(ozone, is.numeric)]  
ozone_qualit <- ozone[, !sapply(ozone, is.numeric)]
```

NOTE:

La fonction `sapply()` applique une fonction (ici `is.numeric`) à chaque élément d'une liste ou d'un tableau et renvoie un vecteur de résultats.

Suppression de lignes

Élimination des lignes selon une condition.

```
ozone_sans_nord <- ozone[ozone$vent != "Nord", ]
```

Tableaux de contingence

Comptage des occurrences et croisements de variables catégorielles.

```
table(ozone$vent)  
table(ozone$vent, ozone$pluie)
```

TP2 - Échantillonnage et Statistique Descriptive

A. Échantillonnage

sample()


Permet de tirer aléatoirement des éléments d'un vecteur ou des lignes d'un tableau.

```
sample_grossebouffe <- grossebouffe[sample(nrow(grossebouffe), 50), ]
```

ASTUCE:

Pour obtenir des résultats reproductibles lors de l'échantillonnage aléatoire, utilisez `set.seed()` avant d'appeler `sample()`.

Exemple d'histogramme représentant la distribution d'une variable :



B. Statistiques descriptives

Effectifs

Comptage du nombre d'observations.

```
n_visites <- length(nb_visites)
```

Moyenne

Calcul de la moyenne arithmétique.

```
moy_visites <- mean(nb_visites)
```

Écart-type

Calcul de l'écart-type, manuellement ou avec la fonction sd().

```
# Méthode manuelle
ecart_visites_man <- sqrt(sum((nb_visites - moy_visites)^2) / (n_visites - 1))
# Méthode automatique
ecart_visites <- sd(nb_visites)
```

Médiane

Calcul de la médiane d'une distribution.

```
med_visites <- median(nb_visites)
```

Tableau récapitulatif

Création d'un tableau de synthèse des statistiques descriptives.

```
tableau_sante <- data.frame(
  Variable = c("Nombre de visites", "Problèmes de santé", "Âge"),
  Effectif = c(n_visites, n_problemes, n_age),
  Moyenne = c(moy_visites, moy_problemes, moy_age),
  Ecart_Type = c(ecart_visites, ecart_problemes, ecart_age),
  Mediane = c(med_visites, med_problemes, med_age)
)
```

C. Loi normale

`pnorm()`

Calcule la fonction de répartition de la loi normale : $P(X \leq x)$.


```
pnorm(344, mean = 340, sd = 6) # P(X < 344)
```

`qnorm()`


Calcule les quantiles de la loi normale.

```
qnorm(0.75, mean = 340, sd = 6) # seuil supérieur 75%
```

Illustration de la loi normale standard avec les zones critiques ($\alpha = 5\%$) :



Comparaison de différentes distributions de probabilité :



ASTUCE:

Les fonctions `dnorm()`, `pnorm()`, `qnorm()` et `rnorm()` sont les quatre fonctions essentielles pour travailler avec la loi normale. Elles calculent respectivement la densité, la fonction de répartition, les quantiles et des valeurs aléatoires.

TP3 - Graphiques en R

A. Histogrammes

hist()

Crée un histogramme pour visualiser la distribution d'une variable numérique.


```
hist(graphique$max03, probability = TRUE, col = "skyblue",  
     main = "Histogramme (densité)", xlab = "max03")
```

density()

Estime la densité de probabilité d'une variable.

```
lines(density(graphique$max03, na.rm = TRUE), col = "red", lwd = 2)
```

Exemple d'histogramme avec courbe de densité :




B. Diagrammes en bâtons

barplot()

Crée un diagramme en bâtons, utile pour les variables catégorielles.

```
barplot(table(graphique$vent), col = "lightgray", main = "Relevés par vent")
```

Exemple de diagramme en bâtons avec couleurs par catégorie :



NOTE:

Pour les variables catégorielles, utilisez `barplot()` avec `table()` pour compter les occurrences de chaque modalité.


C. Nuages de points

plot()

Fonction graphique polyvalente, souvent utilisée pour les nuages de points.

```
plot(graphique$T12, graphique$max03, xlab = "Température à midi", ylab = "max03",  
      main = "Nuage de points", pch = 19, col = "darkblue")
```

Exemple de nuage de points montrant la relation entre deux variables avec gradient de couleurs :



ASTUCE:

Le paramètre `pch` permet de choisir la forme des points (`pch=19` pour des cercles pleins, `pch=1` pour des cercles vides, etc.).


D. Boîtes à moustaches

boxplot()

Crée une boîte à moustaches, utile pour comparer des distributions.

```
boxplot(maxO3 ~ vent, data = graphique, col = "lightblue",  
        main = "Ozone par direction du vent")
```

Exemple de boîtes à moustaches comparant des distributions par groupe avec points individuels :



NOTE:

La formule $y \sim x$ dans `boxplot()` permet de créer une boîte à moustaches pour chaque modalité de x .

TP4 - Loi Normale et Intervalles de Confiance

A. Intervalles de confiance théoriques

Intervalle de confiance

Construction d'un intervalle de confiance pour une moyenne.

```
# Pour une loi normale
z <- qnorm(0.975)
borneInf <- mu - z * sigma / sqrt(n)
borneSup <- mu + z * sigma / sqrt(n)
```

Intervalle avec loi de Student


Utilisation de la loi de Student pour les petits échantillons.

```
t <- qt(0.975, df = n - 1)
marge <- t * ecart / sqrt(n)
cat("IC 95% :", round(moyenne - marge, 2), "-", round(moyenne + marge, 2))
```

ASTUCE:

Pour les petits échantillons ($n < 30$), utilisez la loi de Student (qt) plutôt que la loi normale (qnorm).

Exemple de régression linéaire avec intervalle de confiance :



TP5 - Distribution d'Échantillonnage et Tests

A. Distribution d'échantillonnage

Simulation d'échantillonnage

Génération de multiples échantillons pour étudier la distribution d'une statistique.

```
moyennes.echantillons <- numeric(500)
for (i in 1:500) {
  echantillon <- adultes[sample(nrow(adultes), 40), ]
  moyennes.echantillons[i] <- mean(echantillon$Whole.weight)
}
```

NOTE:

La distribution d'échantillonnage de la moyenne tend vers une loi normale lorsque la taille d'échantillon augmente (théorème central limite).

Test de normalité

Vérification de la normalité d'une distribution.

```
shapiro.test(moyennes.echantillons)
qqnorm(moyennes.echantillons, col="red")
qqline(moyennes.echantillons, col="blue", lw=5)
```

ASTUCE:

Le graphique Q-Q plot (qqnorm) est un outil visuel puissant pour vérifier la normalité. Les points doivent s'aligner sur la droite diagonale.

Conclusion

Cette synthèse présente les principales fonctions et techniques R utilisées dans les travaux pratiques de statistiques. Elle couvre l'importation et la manipulation des données, les statistiques descriptives, la création de graphiques, les intervalles de confiance et la distribution d'échantillonnage.

Pour approfondir vos connaissances, n'hésitez pas à consulter la documentation officielle de R (`help()` ou `?fonction`) ainsi que les nombreuses ressources disponibles en ligne.

ASTUCE:

Astuce finale : R est un langage très puissant pour l'analyse statistique. Prenez le temps d'explorer les packages spécialisés comme `ggplot2` pour les graphiques, `dplyr` pour la manipulation de données, ou `tidyr` pour le nettoyage de données.