


Synthèse Complète des TPs de R



Guide de référence pour comprendre les concepts statistiques fondamentaux et leur implémentation en R

Mai 2025

Table des matières

1. Manipulation des données (TP1)
2. Échantillonnage et statistique descriptive (TP2)
3. Représentations graphiques (TP3)
4. Loi normale et intervalles de confiance (TP4)
5. Distribution d'échantillonnage et tests de conformité (TP5)
6. Glossaire des concepts statistiques

Synthèse Complète des TPs de R (TP1 à TP5)

Introduction

Ce document présente une synthèse complète des concepts, fonctions et méthodes statistiques abordés dans les TPs 1 à 5 du cours de R. Il est conçu comme un guide de référence pour comprendre les concepts statistiques fondamentaux et leur implémentation en R.

Table des matières

1. [Manipulation des données (TP1)](#1-manipulation-des-donnees-tp1)
2. [Échantillonnage et statistique descriptive (TP2)](#2-echantillonnage-et-statistique-descriptive-tp2)
3. [Représentations graphiques (TP3)](#3-representations-graphiques-tp3)
4. [Loi normale et intervalles de confiance (TP4)](#4-loi-normale-et-intervalles-de-confiance-tp4)
5. [Distribution d'échantillonnage et tests de conformité (TP5)](#5-distribution-dechantillonnage-et-tests-de-conformite-tp5)
6. [Glossaire des concepts statistiques](#6-glossaire-des-concepts-statistiques)

1. Manipulation des données (TP1)

Fonction	Description	Exemple
<code>read.table()</code>	Importer des données	<code>donnees <- read.table("fichier.txt")</code>
<code>head()</code>	Afficher les premières lignes	<code>head(donnees, n=5)</code>
<code>nrow()</code> , <code>ncol()</code>	Nombre de lignes/colonnes	<code>nrow(donnees)</code>
<code>donnees\$colonne</code>	Accéder à une colonne	<code>donnees\$age</code>
<code>donnees[condition,]</code>	Filtrer les données	<code>donnees[donnees\$age > 30,]</code>

Importation et exploration des données

```
# Charger un fichier de données
donnees <- read.table(file.choose()) # Boîte de dialogue pour sélectionner un fichier
donnees <- read.csv("chemin/vers/fichier.csv") # Fichier CSV avec en-têtes

# Explorer le jeu de données
View(donnees)           # Afficher les données dans une fenêtre
nrow(donnees)           # Nombre de lignes (observations)
ncol(donnees)           # Nombre de colonnes (variables)
dim(donnees)            # Dimensions (lignes, colonnes)
names(donnees)          # Noms des colonnes
colnames(donnees)       # Équivalent à names()
rownames(donnees)       # Noms des lignes
head(donnees, n=10)     # Afficher les 10 premières lignes
tail(donnees, n=5)      # Afficher les 5 dernières lignes
str(donnees)            # Structure du jeu de données
summary(donnees)        # Résumé statistique de chaque variable
```

Accès aux données

```
# Accéder à une colonne (variable)
donnees[, 3]             # Par position (3e colonne)
donnees$nom_colonne      # Par nom avec $
donnees[["nom_colonne"]] # Par nom avec [[]]

# Accéder à une ligne (observation)
donnees[5, ]            # 5e ligne

# Accéder à une cellule spécifique
donnees[5, 3]           # Ligne 5, colonne 3
donnees[5, "nom_colonne"] # Ligne 5, colonne par nom

# Filtrer les données
donnees_filtrees <- donnees[donnees$variable > 10, ] # Lignes où variable > 10
donnees_filtrees <- donnees[donnees$categorie == "A", ] # Lignes où catégorie = "A"

# Combiner des conditions
donnees_filtrees <- donnees[donnees$variable > 10 & donnees$categorie == "A", ] #
donnees_filtrees <- donnees[donnees$variable > 10 | donnees$categorie == "A", ] #
```

Manipulation des données

```
# Renommer une colonne
names(donnees)[names(donnees) == "ancien_nom"] <- "nouveau_nom"

# Créer une nouvelle variable
donnees$nouvelle_var <- donnees$var1 + donnees$var2
donnees$categorie <- ifelse(donnees$variable > 10, "Élevé", "Faible")

# Extraire des sous-ensembles de variables
donnees_num <- donnees[sapply(donnees, is.numeric)] # Variables numériques
donnees_cat <- donnees[sapply(donnees, is.factor)] # Variables catégorielles

# Supprimer des lignes ou colonnes
donnees_sans_na <- na.omit(donnees) # Supprimer les lignes avec NA
donnees_reduit <- donnees[, -c(2, 4)] # Supprimer les colonnes 2 et 4

# Tableaux de contingence
table(donnees$categorie) # Effectifs d'une variable catégorielle
table(donnees$categorie, donnees$autre_cat) # Tableau croisé
```

À quoi ça sert ? Ces fonctions permettent d'importer, explorer et manipuler vos données avant de procéder à l'analyse statistique. C'est l'étape préliminaire indispensable de toute analyse de données.

2. Échantillonnage et statistique descriptive (TP2)

Statistique	Fonction R	Description
Moyenne	mean()	Somme des valeurs divisée par leur nombre
Médiane	median()	Valeur qui sépare les données en deux parties égales
Écart-type	sd()	Mesure de dispersion autour de la moyenne
Variance	var()	Carré de l'écart-type
Quantiles	quantile()	Valeurs qui divisent les données en parts égales

Échantillonnage aléatoire

```
# Tirage aléatoire d'observations
echantillon <- donnees[sample(nrow(donnees), 50), ] # 50 observations aléatoires
```

Statistiques descriptives

```
# Mesures de tendance centrale
moyenne <- mean(donnees$variable) # Moyenne arithmétique
mediane <- median(donnees$variable) # Médiane
mode <- as.numeric(names(sort(table(donnees$variable), decreasing = TRUE)[1])) # M

# Mesures de dispersion
variance <- var(donnees$variable) # Variance
ecart_type <- sd(donnees$variable) # Écart-type
etendue <- max(donnees$variable) - min(donnees$variable) # Étendue
quartiles <- quantile(donnees$variable, probs = c(0.25, 0.5, 0.75)) # Quartiles
iqr <- IQR(donnees$variable) # Écart interquartile

# Calcul manuel de l'écart-type
n <- length(donnees$variable)
moy <- mean(donnees$variable)
ecart_type_manuel <- sqrt(sum((donnees$variable - moy)^2) / (n - 1))
```

Qu'est-ce que la moyenne ? La moyenne arithmétique est la somme des valeurs divisée par le nombre d'observations. Elle représente le "centre de gravité" des données.

Qu'est-ce que la médiane ? La médiane est la valeur qui sépare les données en deux parties égales (50% au-dessus, 50% en-dessous). Elle est moins sensible aux valeurs extrêmes que la moyenne.

Qu'est-ce que la variance ? La variance mesure la dispersion des valeurs autour de la moyenne. C'est la moyenne des carrés des écarts à la moyenne. Elle s'exprime dans le carré de l'unité des données.

Qu'est-ce que l'écart-type ? L'écart-type est la racine carrée de la variance. Il mesure la dispersion des valeurs autour de la moyenne et s'exprime dans la même unité que les données. Plus l'écart-type est grand, plus les données sont dispersées.

À quoi ça sert ? L'écart-type permet d'évaluer la variabilité d'une distribution. Par exemple, pour une distribution normale, environ 68% des valeurs se situent à ± 1 écart-type de la moyenne, et 95% à ± 2 écarts-types.

Loi normale et probabilités


```
# Densité de probabilité (PDF)
dnorm(x, mean = 0, sd = 1) # Densité de probabilité au point x

# Fonction de répartition (CDF)
pnorm(q, mean = 0, sd = 1) #  $P(X \leq q)$ 
1 - pnorm(q, mean = 0, sd = 1) #  $P(X > q)$ 
pnorm(b, mean = 0, sd = 1) - pnorm(a, mean = 0, sd = 1) #  $P(a < X \leq b)$ 

# Quantiles
qnorm(p, mean = 0, sd = 1) # Valeur q telle que  $P(X \leq q) = p$ 

# Génération de nombres aléatoires
rnorm(n, mean = 0, sd = 1) # n nombres aléatoires suivant  $N(0,1)$ 
```

Illustration de la loi normale:



Qu'est-ce que la loi normale ? La loi normale (ou gaussienne) est une distribution de probabilité symétrique en forme de cloche. Elle est caractérisée par sa moyenne μ et son écart-type σ . La loi normale centrée réduite a $\mu=0$ et $\sigma=1$.

À quoi ça sert ? La loi normale est fondamentale en statistique car de nombreux phénomènes naturels suivent approximativement cette distribution. Elle est aussi utilisée pour approximer d'autres distributions grâce au théorème central limite.

3. Représentations graphiques (TP3)


Histogrammes

```
# Histogramme simple
hist(donnees$variable, main = "Titre", xlab = "Axe X", ylab = "Fréquence")

# Histogramme en densité
hist(donnees$variable, probability = TRUE, col = "skyblue",
     main = "Histogramme (densité)", xlab = "Variable")
lines(density(donnees$variable), col = "red", lwd = 2) # Ajouter la courbe de densité

# Histogramme avec classes personnalisées
breaks <- seq(min(donnees$variable), max(donnees$variable), by = 10)
hist(donnees$variable, breaks = breaks, col = "lightgreen")
```

Exemple visuel d'un histogramme:



À quoi ça sert ? L'histogramme permet de visualiser la distribution d'une variable numérique en regroupant les données en classes. Il aide à identifier la forme de la distribution (symétrique, asymétrique, unimodale, bimodale, etc.).


Diagrammes en bâtons et polygones des effectifs

```
# Diagramme en bâtons
barplot(table(donnees$categorie), col = "skyblue",
       main = "Diagramme en bâtons", xlab = "Catégorie", ylab = "Effectifs")

# Polygone des effectifs
hist_data <- hist(donnees$variable, plot = FALSE)
plot(hist_data$mids, hist_data$counts, type = "o", col = "blue",
     xlab = "Variable", ylab = "Effectifs", main = "Polygone des effectifs")

# Effectifs cumulés
cum_count <- cumsum(hist_data$counts)
plot(hist_data$mids, cum_count, type = "s", col = "darkgreen",
     xlab = "Variable", ylab = "Effectifs cumulés", main = "Effectifs cumulés")
```

Exemple visuel d'un histogramme:



À quoi ça sert ? Le diagramme en bâtons est utilisé pour représenter les effectifs de variables catégorielles. Le polygone des effectifs et la courbe des effectifs cumulés permettent de visualiser la distribution et la répartition des données.

Nuages de points et boîtes à moustaches


```
# Nuage de points
plot(donnees$var1, donnees$var2, xlab = "Variable 1", ylab = "Variable 2",
     main = "Nuage de points", pch = 19, col = "darkblue")

# Boîte à moustaches (boxplot)
boxplot(donnees$variable, main = "Boîte à moustaches", col = "lightblue")

# Boîte à moustaches par groupe
boxplot(variable ~ categorie, data = donnees, col = "lightblue",
        main = "Variable par catégorie")

# Boîtes à moustaches multiples
boxplot(donnees[, c("var1", "var2", "var3")], col = c("red", "green", "blue"),
        main = "Comparaison de variables")
```

Exemple visuel d'une boîte à moustaches:



Qu'est-ce qu'une boîte à moustaches ? La boîte à moustaches (boxplot) représente la distribution d'une variable numérique à travers ses quartiles. La boîte centrale s'étend du 1er au 3e quartile (écart interquartile), avec une ligne à la médiane. Les "moustaches" s'étendent jusqu'aux valeurs extrêmes non aberrantes. Les points isolés représentent les valeurs aberrantes.


À quoi ça sert ? Le nuage de points permet de visualiser la relation entre deux variables numériques. La boîte à moustaches permet de visualiser la distribution d'une variable et de détecter les valeurs aberrantes.

Graphiques combinés et personnalisés

```
# Combiner plusieurs graphiques
par(mfrow = c(2, 2)) # Diviser la fenêtre graphique en 2x2
hist(donnees$var1)
boxplot(donnees$var1)
plot(donnees$var1, donnees$var2)
barplot(table(donnees$categorie))
par(mfrow = c(1, 1)) # Restaurer la fenêtre graphique


# Personnaliser les graphiques
plot(donnees$var1, donnees$var2,
     main = "Titre principal", sub = "Sous-titre",
     xlab = "Axe X", ylab = "Axe Y",
     col = "red", pch = 19, cex = 1.5,
     xlim = c(0, 100), ylim = c(0, 50))
abline(h = mean(donnees$var2), col = "blue", lty = 2) # Ligne horizontale
abline(v = mean(donnees$var1), col = "green", lty = 2) # Ligne verticale
legend("topright", legend = c("Données", "Moyenne X", "Moyenne Y"),
     col = c("red", "green", "blue"), pch = c(19, NA, NA),
     lty = c(NA, 2, 2))
```

Exemple visuel d'un histogramme:



À quoi ça sert ? Les graphiques combinés permettent de comparer différentes visualisations des mêmes données. La personnalisation des graphiques permet de mettre en évidence les aspects importants des données.

4. Loi normale et intervalles de confiance (TP4)



Intervalles de confiance pour la moyenne

```
# Intervalle de confiance pour la moyenne (loi normale,  $\sigma$  connu)
mu <- mean(donnees$variable)
sigma <- sd(donnees$variable) # En pratique,  $\sigma$  est rarement connu
n <- length(donnees$variable)
alpha <- 0.05 # Niveau de confiance de 95%
z <- qnorm(1 - alpha/2) # Quantile de la loi normale
marge <- z * sigma / sqrt(n)
ic <- c(mu - marge, mu + marge) # Intervalle de confiance

# Intervalle de confiance pour la moyenne (loi de Student,  $\sigma$  inconnu)
s <- sd(donnees$variable)
t <- qt(1 - alpha/2, df = n - 1) # Quantile de la loi de Student
marge <- t * s / sqrt(n)
ic <- c(mu - marge, mu + marge) # Intervalle de confiance

# Intervalle de confiance avec t.test()
t_test <- t.test(donnees$variable, conf.level = 0.95)
ic <- t_test$conf.int # Intervalle de confiance
```


Qu'est-ce qu'un intervalle de confiance ? Un intervalle de confiance est une plage de valeurs qui a une certaine probabilité (niveau de confiance) de contenir le vrai paramètre de la population. Par exemple, un intervalle de confiance à 95% pour la moyenne signifie que si on répétait l'échantillonnage un grand nombre de fois, environ 95% des intervalles calculés contiendraient la vraie moyenne de la population.

Quand utiliser la loi normale vs. la loi de Student ? On utilise la loi normale quand l'écart-type de la population (σ) est connu ou quand la taille de l'échantillon est grande ($n > 30$). On utilise la loi de Student quand σ est inconnu et que l'échantillon est petit ($n \leq 30$).

À quoi ça sert ? Les intervalles de confiance permettent d'estimer un paramètre de population (comme la moyenne) avec une marge d'erreur, reflétant l'incertitude

due à l'échantillonnage.

5. Distribution d'échantillonnage et tests de conformité (TP5)



Distribution d'échantillonnage

```
# Simulation de la distribution d'échantillonnage de la moyenne
n_simulations <- 500
taille_echantillon <- 40
moyennes <- numeric(n_simulations)

for (i in 1:n_simulations) {
  echantillon <- sample(population, taille_echantillon, replace = TRUE)
  moyennes[i] <- mean(echantillon)
}

# Visualisation de la distribution d'échantillonnage
hist(moyennes, probability = TRUE, main = "Distribution d'échantillonnage")
lines(density(moyennes), col = "red", lwd = 2)

# Test de normalité
shapiro.test(moyennes) # Test de Shapiro-Wilk
qqnorm(moyennes) # Graphique Quantile-Quantile
qqline(moyennes) # Ligne de référence
```

Qu'est-ce que la distribution d'échantillonnage ? La distribution d'échantillonnage d'une statistique (comme la moyenne) est la distribution des valeurs de cette statistique calculées à partir de tous les échantillons possibles de même taille tirés de la même population.

Théorème central limite : Selon ce théorème, la distribution d'échantillonnage de la moyenne tend vers une loi normale quand la taille de l'échantillon augmente, quelle que soit la distribution de la population d'origine. C'est pourquoi on peut utiliser la loi normale pour construire des intervalles de confiance et réaliser des tests d'hypothèse sur les moyennes, même si la population n'est pas normalement distribuée, à condition que l'échantillon soit suffisamment grand (généralement $n > 30$).

Tests de conformité pour la moyenne

```
# Test de conformité pour la moyenne (test t)
mu0 <- 100 # Valeur de référence
t_test <- t.test(donnees$variable, mu = mu0)
t_test # Affiche les résultats du test

# Test manuel
moyenne <- mean(donnees$variable)
ecart_type <- sd(donnees$variable)
n <- length(donnees$variable)
t_stat <- (moyenne - mu0) / (ecart_type / sqrt(n))
p_value <- 2 * (1 - pt(abs(t_stat), df = n - 1)) # Test bilatéral

# Tests unilatéraux
t_test_inf <- t.test(donnees$variable, mu = mu0, alternative = "less") # H1:  $\mu < \mu_0$ 
t_test_sup <- t.test(donnees$variable, mu = mu0, alternative = "greater") # H1:  $\mu > \mu_0$ 
```

Qu'est-ce qu'un test de conformité ? Un test de conformité (ou test d'hypothèse) permet de déterminer si un paramètre de population (comme la moyenne) est significativement différent d'une valeur de référence. Le test compare une hypothèse nulle ($H_0: \mu = \mu_0$) à une hypothèse alternative ($H_1: \mu \neq \mu_0, \mu < \mu_0$ ou $\mu > \mu_0$).

Qu'est-ce que la p-value ? La p-value est la probabilité d'obtenir un résultat au moins aussi extrême que celui observé, sous l'hypothèse nulle. Une p-value faible (généralement < 0.05) indique que les données sont incompatibles avec l'hypothèse nulle, ce qui conduit à la rejeter.

À quoi ça sert ? Les tests de conformité permettent de prendre des décisions basées sur des données, en évaluant si les différences observées sont statistiquement significatives ou simplement dues au hasard de l'échantillonnage.

Tests de conformité pour la variance

```
# Test de conformité pour la variance (test du chi-deux)
sigma0_carre <- 100 # Variance de référence
n <- length(donnees$variable)
s_carre <- var(donnees$variable)
chi_carre <- (n - 1) * s_carre / sigma0_carre
p_value <- 2 * min(pchisq(chi_carre, df = n - 1), 1 - pchisq(chi_carre, df = n - 1))

# Test F pour comparer deux variances
var_test <- var.test(groupe1$variable, groupe2$variable)
var_test # Affiche les résultats du test
```

Qu'est-ce qu'un test de conformité pour la variance ? Ce test permet de déterminer si la variance d'une population est significativement différente d'une valeur de référence, ou si les variances de deux populations sont significativement différentes.

À quoi ça sert ? Les tests sur la variance sont importants pour vérifier l'homogénéité des variances, une hypothèse souvent requise pour d'autres tests.

statistiques comme le test t pour deux échantillons indépendants.

6. Glossaire des concepts statistiques

Concepts de base

- **Population** : Ensemble complet des individus ou objets d'intérêt.
- **Échantillon** : Sous-ensemble de la population, utilisé pour estimer les caractéristiques de la population.
- **Variable** : Caractéristique mesurée sur chaque individu de la population ou de l'échantillon.
- **Variable quantitative** : Variable qui prend des valeurs numériques (ex: taille, poids).
- **Variable qualitative** : Variable qui prend des valeurs catégorielles (ex: couleur, sexe).

Statistiques descriptives

- **Moyenne** : Somme des valeurs divisée par le nombre d'observations. Mesure de tendance centrale sensible aux valeurs extrêmes.
- **Médiane** : Valeur qui sépare les données en deux parties égales. Mesure de tendance centrale robuste aux valeurs extrêmes.
- **Mode** : Valeur la plus fréquente dans un ensemble de données.
- **Variance** : Moyenne des carrés des écarts à la moyenne. Mesure de dispersion.
- **Écart-type** : Racine carrée de la variance. Mesure de dispersion dans la même unité que les données.
- **Quartiles** : Valeurs qui divisent les données en quatre parties égales.
- **Écart interquartile (IQR)** : Différence entre le 3e et le 1er quartile. Mesure de dispersion robuste aux valeurs extrêmes.

Probabilités et distributions

- **Loi normale** : Distribution de probabilité symétrique en forme de cloche, caractérisée par sa moyenne μ et son écart-type σ .
- **Loi de Student** : Distribution utilisée quand l'écart-type de la population est inconnu et que l'échantillon est petit.
- **Distribution d'échantillonnage** : Distribution d'une statistique calculée à partir de tous les échantillons possibles de même taille.
- **Théorème central limite** : La distribution d'échantillonnage de la moyenne tend vers une loi normale quand la taille de l'échantillon augmente.

Inférence statistique

- **Estimation ponctuelle** : Utilisation d'une seule valeur (statistique) pour estimer un paramètre de population.
- **Intervalle de confiance** : Plage de valeurs qui a une certaine probabilité de contenir le vrai paramètre de la population.
- **Niveau de confiance** : Probabilité que l'intervalle de confiance contienne le vrai paramètre (ex: 95%).
- **Test d'hypothèse** : Procédure pour déterminer si un paramètre de population est significativement différent d'une valeur de référence.
- **Hypothèse nulle (H_0)** : Hypothèse par défaut, généralement formulée comme l'absence d'effet ou de différence.
- **Hypothèse alternative (H_1)** : Hypothèse concurrente, généralement ce que le chercheur veut démontrer.
- **Statistique de test** : Valeur calculée à partir des données pour évaluer l'hypothèse nulle.
- **p-value** : Probabilité d'obtenir un résultat au moins aussi extrême que celui observé, sous l'hypothèse nulle.
- **Seuil de signification (α)** : Niveau de risque accepté pour rejeter l'hypothèse nulle alors qu'elle est vraie (généralement 5%).
- **Puissance statistique** : Probabilité de rejeter l'hypothèse nulle quand elle est fausse.

Conclusion

Cette synthèse couvre les principaux concepts et fonctions abordés dans les TPs 1 à 5 du cours de R. Elle peut servir de référence pour comprendre les concepts statistiques et leur

implémentation en R. Pour approfondir ces notions, n'hésitez pas à consulter la documentation R ([?fonction](#)) et des ressources complémentaires sur la statistique.