

Haute Ecole de la Province de Liège

CATÉGORIE SCIENCES ET TECHNIQUES

Traitement statistique des données

Exercices

Anne Léonard
Patrick Quettier
Claude Vilvens

Bachelier en informatique
Orientation développement d'applications
B2

Siège social :
Avenue Montesquieu, 6
4101 Jemeppe (Seraing)
Belgique

ANNÉE ACADÉMIQUE 2024-2025

T.P. Data n°1: Manipulations des données en R

Objectif : Savoir récupérer des données en R et les manipuler

1. Big data : récupération et mise en forme des données

La pollution de l'air constitue actuellement une des préoccupations majeures de santé publique. De nombreuses études épidémiologiques ont permis de mettre en évidence l'influence sur la santé de certains composés chimiques comme l'ozone (O3).

Des associations de surveillance de la qualité de l'air se sont donné comme mission de construire des modèles de prévision de la concentration en ozone du lendemain à partir des données météo disponibles chaque jour. Plus précisément, il s'agit d'anticiper l'occurrence ou non d'un dépassement légal du pic d'ozone (180 µgr/m3) le lendemain afin d'aider les autorités à prendre les décisions nécessaires de prévention (confinement des personnes à risque, limitation du trafic routier, ...).

L'étude disponible dans le fichier **etude-ozone-bretagne-2011.txt** est de mettre en évidence l'influence de certains paramètres sur la concentration d'ozone (en µgr/m3) et différentes variables observées ou leur prévision. Les 112 données étudiées ont été recueillies en Bretagne. Les 13 variables observées sont :

- ◆ MaxO3 : Maximum de concentration d'ozone observé sur la journée en gr/m3
- ◆ T9, T12, T15 : Température observée à 9, 12 et 15h
- ◆ Ne9, Ne12, Ne15 : Nébulosité observée à 9, 12 et 15h
- ◆ Vx9, Vx12, Vx15 : Composante E-O du vent à 9, 12 et 15h
- ◆ MaxO3v : Teneur maximum en ozone observée la veille
- ◆ vent: orientation du vent à 12h
- ◆ pluie : occurrence ou non de précipitations

Il s'agit ici, **en utilisant R** (en mode console ou avec RStudio) de réaliser toute une série de traitements.

Tout d'abord, il s'agit de lire l'ensemble des données de manière correcte, en distinguant les variables quantitatives et qualitatives.

1. Lire les données dans une variable (dataset) "ozone" de R; vérifier que la lecture s'est bien passée avec la fonction `summary()` et un éditeur ASCII comme JEdit ou Notepad
2. Combien de lignes, de colonnes ?
3. Quels sont les noms des lignes et des colonnes ?
4. Qu'apporte comme information la fonction `str()` appliquée à "ozone" ?
5. Créer une variable contenant la 3^{ème} colonne du dataset de 3 manières différentes

2. Manipulations des données

On demande de

1. Changer le nom de la colonne "Pluie" en "Pluies"
2. Récupérer dans une variable les données correspondant à un taux d'ozone de minimum 85
3. Récupérer dans une variable les données correspondant à un temps sec
4. Récupérer dans une variable les données correspondant à un temps sec et à un taux d'ozone de minimum 95
5. Changer les modalités de la variable "Pluies" en "Oui" et "Non"
6. Créer un dataset "ozone.quanti" ne contenant que les variables quantitatives
7. Créer un dataset "ozone.quali" ne contenant que les variables qualitatives

8. Créer un dataset à partir d'ozone en retirant les lignes correspondant à des vents du nord
9. Compter le nombre de relevés selon chaque direction du vent
10. Compter le nombre de relevés selon chaque direction du vent par temps de pluie ou pas

T.P. Data n°2: Echantillonnage, statistique descriptive et loi normale

Objectif : Revoir la statistique descriptive en R et maîtriser l'utilisation de la loi normale avec l'aide de R

1. Echantillonnage

Le fichier **bonne_sante.csv** contient le résultat d'une petite étude réalisée en Allemagne sur "je me considère ne bonne santé" ou pas. 1127 personnes ont été interrogés sur

- ♦ numvisit : le nombre de visites chez le médecin en un an
- ♦ badh: le fait de se sentir bien, en bonne santé (0) ou au contraire en mauvaise santé (1)
- ♦ age: l'âge du patient

On demande tout d'abord d'isoler le nombre de visites chez le médecin puis de construire un échantillon de 50 éléments à partir des données complètes en utilisant la fonction R `sample()`.

2. Statistique descriptive

Il s'agit à présent de réaliser l'étude statistique descriptive complète de cet échantillon (moyenne, écart-type, médiane, ...); en particulier, calculer manuellement l'écart-type de l'échantillon et le comparer à celui fourni par la fonction `sd()`; on demande aussi de construire au fur et à mesure un vecteur tableau.sante.visite.ech.descriptive contenant l'effectif, la moyenne, l'écart-type (de l'échantillon) et la médiane avec des noms de colonnes appropriés :

effectif	moyenne	écart-type	médiane
...	...	...	...

3. La loi normale

L'entreprise GROSSEBOUFFE distribue ses conserves de petits pois dans une boîte métallique dont le poids après remplissage est en moyenne de 340 grammes. Il est possible d'ajuster le processus de remplissage pour obtenir une valeur moyenne désirée. La distribution suit une loi d'écart-type de 6 g.

- a) Quelle est la probabilité qu'une boîte choisie au hasard ait un poids inférieur à 344 g?
- b) Quelle est la probabilité qu'une boîte choisie au hasard ait un poids inférieur à 339 g?
- c) Quelle est la probabilité qu'une boîte choisie au hasard ait un poids supérieur à 343 g?
- d) Quelle est la probabilité qu'une boîte choisie au hasard ait un poids entre 334 et 346 g ?
- e) Quelle est la probabilité qu'une boîte choisie au hasard ait un poids qui diffère de la moyenne par moins de 2 grammes ?
- f) Quelle est la limite supérieure du poids de 75% des boîtes ?
- g) Quelle est la limite inférieure du poids de 80% des boîtes ?
- h) Sur une production de 1000 boîtes, combien auront un poids inférieur à 330 g ?
- i) A quelle valeur doit être fixée le niveau de remplissage pour assurer que seulement une boîte sur 100 aura un poids inférieur à 340 g ?

T.P. Data n°3: Graphiques en R

Objectif : Revoir la statistique descriptive en R et maîtriser l'utilisation de la loi normale avec l'aide de R
--

1. Graphiques de base

On passe à présent à la visualisation des données extraites du fichier **etude-ozone-bretagne-2011.txt**. On demande de réaliser les graphiques statistiques suivants pour toutes les observations :

1. un histogramme en densité du taux maximum d'ozone; comment vérifier qu'il s'agit bien d'une densité de probabilité ?
2. un histogramme amélioré qui regroupe les dernières classes;
3. un diagramme en bâtonnets;
4. un graphique linéaire type "polygone des effectifs";
5. la superposition de l'histogramme et du polygone des effectifs;
6. un graphique des effectifs cumulés;
7. un nuage de points "concentration maximum d'ozone" et "température à midi";
8. une représentation de la concentration d'ozone selon chaque direction du vent;
9. une représentation de la concentration d'ozone selon chaque direction du vent par temps de pluie ou pas
10. une comparaison de la répartition pluie/sec selon la direction du vent;
11. une comparaison de la concentration d'ozone selon la direction du vent.
12. deux nuages de points de la concentration maximum d'ozone en fonction de la température à midi selon la présence ou l'absence de pluie;
13. la ventilation du nombre de relevés selon chaque direction du vent;
14. la ventilation du nombre de relevés selon chaque direction du vent par temps de pluie ou pas.

T.P. Data n°4: Loi normale et intervalles de confiance d'échantillons en R

Objectif : Maîtriser et mettre en pratique les concepts des théories de l'échantillonnage et de l'estimation

1. Intervalle de confiance de la moyenne des échantillons

1.1. La teneur en protéines diverses dans le lait des vaches CharolaisDesBalkans a pour moyenne reconnue 33 g/l avec un écart-type de 3 g/l. Quel est l'intervalle de confiance de la moyenne des échantillons de 50 mesures de cette population pour un niveau de confiance de 95% ?

Et que penser de cet échantillon :

31.16338	33.36843	33.82556	33.26381	31.20354	34.70892	33.22151	29.59992	34.53175	30.25163
30.44263	32.03892	32.49695	24.95243	36.84046	29.59009	33.17207	30.08791	33.16156	28.58702
31.05602	31.91366	32.37426	28.42104	38.99676	32.09157	32.02571	30.18006	29.72563	36.12458
35.26049	32.40710	33.87204	31.98163	32.37071	28.19409	34.67374	28.56197	32.50710	35.40063
35.24677	32.06770	27.49695	34.34093	29.36503	32.65692	36.67540	34.96778	35.19970	34.90146

traité ces derniers jours ? Cet échantillon est-il à considérer comme "normal" ou pas pour un niveau de confiance de 95% ?

1.2 Le contrôleur de production d'une fabrique de boulons en titane $16 \pm 0.3 \times 50 \pm 0.2$ a réalisé une série de mesures sur le diamètre et la longueur de 20 boulons pris au hasard. Les résultats de ses mesures sont :

diamètre	longueur
15.71	50.11
15.94	50.01
16.02	50.63
15.94	50.22
15.87	50.06
16.92	49.97
16.01	50.12
15.94	50.12
15.93	NA
15.95	50.07
16.02	50.10
16.11	49.87
15.97	49.94
16.14	49.95
15.89	50.09
16.10	NA
15.97	49.92
15.95	49.99
16.04	50.00
16.07	49.97

Il s'est rendu compte un peu tard que, pour deux boulons, il avait oublié de mesurer la longueur et les avait déjà remis dans le tas de boulons produits.

Cet échantillon permet-il de détecter, à un niveau de confiance de 95%, des problèmes de production sur les diamètres et/ou sur les longueurs des boulons produits ?

Les données sont disponibles dans le fichier **boulons_distrain.csv**.

2. Estimation de moyenne d'une population

2.1 Le Syndicat des Joyeux Libraires a mandaté une enquête sur le temps passé par les clients qui visitent une librairie "classique" (donc pas une FNAC ou une grande surface). L'intérêt est d'estimer si le client doit être attiré en très peu de temps par des offres "coup de poing" ou si, au contraire, il convient de lui laisser le temps de découvrir les livres exposés un peu partout dans le magasin. Pour un échantillon de 80 clients choisis aléatoirement et qui ont effectivement acheté au moins un livre, on a obtenu une moyenne 43 min, avec un écart-type de 14 min.

Estimer par intervalle de confiance à 90% la durée moyenne d'une visite.

2.2 La Corporation des Bijoutiers Sérieux a eu vent de l'enquête des libraires et a donc réalisé une enquête similaire. Cette fois, l'échantillon de 18 clients a donné un temps moyen de 29 min avec un écart-type de 13 min.

Estimer par intervalle de confiance à 95% la durée moyenne d'une visite.

2.3 On revient aux données portant sur l'ozone en Bretagne du fichier **etude-ozone-bretagne-2011.txt**.

a) Quel est l'intervalle de confiance pour le maximum de concentration d'ozone observé sur la journée en Bretagne ?

b) Même question pour les variables T9, T12, T15, Ne9, Ne12, Ne15, Vx9, Vx12 et Vx15.

T.P. Data n°5: Distribution d'échantillonnage et tests de conformité

Objectifs :

- ◆ Maîtriser la notion de distribution d'échantillonnage
- ◆ Savoir réaliser un test d'hypothèse de conformité de moyenne et de variance classiquement et par p-value

1. Distribution d'échantillonnage d'une moyenne

Il s'agit ici de simuler le tirage d'un grand nombre d'échantillons d'une même population afin d'établir expérimentalement la forme de la distribution d'échantillonnage de la moyenne.

1.1 Les données de référence ont été établies par les Marine Research Laboratories (Marine Resources Division) de Hobart (Taroona), Tasmanie, Australie. Elles concernent diverses mesures portant sur des coquillages nommés Ormeaux (Abalones en anglais), gastéropodes très appréciés en gastronomie mais très difficile à reproduire en élevage (on y cependant parvenu en Bretagne depuis quelques années). Ce genre d'enquêtes est donc d'un intérêt économique que biologique.

Les données sont disponibles dans le fichier **OrmeauxAbalones.csv**. Les variables utilisées figurent dans le rapport :

Name	Data Type	Meas.	Description
----	-----	-----	-----
Sex	nominal		M, F, and I (infant)
Length	continuous	mm	Longest shell measurement
Diameter	continuous	mm	perpendicular to length
Height	continuous	mm	with meat in shell
Whole weight	continuous	grams	whole abalone
Shucked weight	continuous	grams	weight of meat
Viscera weight	continuous	grams	gut weight (after bleeding)
Shell weight	continuous	grams	after being dried
Rings	integer		+1.5 gives the age in years

Il s'agit donc tout d'abord de lire ces données et de vérifier leur bon état. Représenter graphiquement le poids des animaux de l'enquête. En particulier, que donne l'usage de la fonction `plot()` appliquée à tout le data frame ?

1.2 En pratique, vu la relative rareté des ormeaux et le temps prohibitif pris par ces mesures, un éleveur ne pourra mesurer qu'un nombre limité d'animaux. On demande d'abord de construire un échantillon aléatoire de 40 individus adultes.

1.3 On demande ensuite d'écrire un script R qui va générer 500 échantillons du type précédent; les moyennes de ces échantillons seront placées dans un tableau `moyennes.echantillons`. Il reste alors à représenter graphiquement la distribution de ces moyennes. Comment voir si on obtient une distribution plus ou moins normale ? Est-elle en accord avec ce que prévoit la théorie ?

Le directeur qui recevra votre rapport a déjà une question : "Au fait, à quoi ressemble un ormeau ?" ...

2. Tests de conformité de moyenne et de variance

2.1 L'entreprise ToutEnFinesse fabrique des tôles de divers métaux, dont un alliage FeSn très apprécié pour les miroirs paraboliques. L'épaisseur nominale des tôles TP003 est de 0.5 mm, avec une tolérance de 0.0025. Un contrôle de production portant sur un échantillon de 50 tôles de ce type a donné une moyenne de 0.54 mm avec un écart-type de 0.0023 mm. Quelles conclusions en tirer quant au respect de la valeur nominale et de sa tolérance, ceci à un seuil de 5% ?

Un deuxième contrôle pour seulement 20 tôles a donné une moyenne de 0.515 mm avec un écart-type de 0.0027 mm. Cela change-t-il quelque chose à la conclusion précédente ?

Utiliser sous R le test prédéfini (si il existe !) et le calcul manuel de la p-value afin de vérifier les valeurs manipulées..

2.2 La société PacteExcellence a mis au point un test d'évaluation des jeunes gens de 18 ans visant à tester leur préparation à l'enseignement supérieur de type long de type scientifique. Le test a été construit avec comme objectif que les élèves du secondaire en position optimale pour cet enseignement obtiennent un résultat de 15 (sur 30) avec une marge d'erreur de 6. Des notes qui s'écartent dans un sens ou dans l'autre devraient révéler une certaine inaptitude.

Un test a été réalisé il y a un an sur 20 étudiants actuellement en 2^{ème} bachelier en sciences :

14.9	15.6	14.7	15.3	14.7	15.2	15.4	23.7	14.9	15.0
15.6	14.4	14.3	15.3	15.3	15.9	13.9	14.2	16.2	14.8

Utiliser sous R le test prédéfini (si il existe !) et le calcul manuel de la p-value afin de vérifier les valeurs manipulées.

2.3 La société MecaFluides produits divers types de tuyaux destinés à s'emboîter les uns dans les autres, la petite extrémité ayant un diamètre interne moyen de 20 cm et la grande un diamètre interne moyen de 20.5 cm. On a mesuré aux deux extrémités 50 tuyaux de 4m de long. Les résultats sont le fichier **tuyaux.csv**. Peut-on considérer ces tuyaux comme conformes ou pas (au seuil de 5%) ?

Il est conseillé de réaliser au préalable un diagramme à moustaches pour détecter les éventuelles valeurs aberrantes, celles-ci étant éliminées dans le dataset correspondant de R mais pas dans le fichier original.

2.4 On dispose d'un rapport sur les salaires bruts en 2013 de 3000 travailleurs masculins des états du centre-est des U.S.A. Les données disponibles se trouvent dans le fichier **Wage.csv** et sont décrites dans le rapport :

Description

Wage and other data for a group of 3000 male workers in the Mid-Atlantic region.

Usage

Wage

Format

A data frame with 3000 observations on the following 11 variables.

- year : Year that wage information was recorded
- age : Age of worker
- maritl : A factor with levels 1. Never Married 2. Married 3. Widowed 4. Divorced and 5. Separated indicating marital status
- race : A factor with levels 1. White 2. Black 3. Asian and 4. Other indicating race
- education : A factor with levels 1. < HS Grad 2. HS Grad 3. Some College 4. College Grad and 5. Advanced Degree indicating education level
- region : Region of the country (mid-atlantic only)
- jobclass : A factor with levels 1. Industrial and 2. Information indicating type of job
- health : A factor with levels 1. <=Good and 2. >=Very Good indicating health level of worker
- health_ins : A factor with levels 1. Yes and 2. No indicating whether worker has health insurance
- logwage : Log of workers wage
- wage : Workers raw wage

On demande tout d'abord d'utiliser ces données pour évaluer les moyennes et variances de la population des diplômés de l'enseignement supérieur.

On a ensuite interrogé en 2015 20 travailleurs diplômés de l'enseignement supérieur et de la même région à propos de leur salaire. Peut-on considérer que l'on observe par rapport aux données antérieures une différence significative de moyenne ou de variance à 90% de niveau de confiance ? Les salaires de l'échantillon sont :

203.38533	121.88416	111.49562	139.95027	228.34125
122.02483	22.20924	125.33475	154.40833	172.01973
92.34485	217.89828	81.25847	84.37009	41.24959
108.99464	103.92393	113.41895	224.26264	112.95314

T.P. Data n°6: Tests d'homogénéité

Objectifs : Savoir réaliser un test d'hypothèse d'homogénéité de moyennes et de variances classiquement et par p-value

1. Tests d'homogénéité de moyenne et de variance

1.1 Le pourcentage en humidité de croquettes pour chat est étudié par d'éminents membres la faculté de médecine vétérinaire de l'Université de Batracie, cela pour les deux marques Yahboncat et Miaoubueno. On a obtenu les résultats suivants pour deux échantillons extraits des productions des deux marques :

	Yahboncat	Miaoubueno
n	24	68
m	73.2	76.6
s	10.9	11.4

En privilégiant les tests unilatéraux, au seuil de 5%, les Yahboncat peuvent-ils être considérés comme similaires en tous points aux Miaoubueno?

1.2 La société PipelineForThePeople fabrique deux types de tuyaux d'écoulement, selon deux procédés de fabrication similaires mais distincts, avec des alliages assez voisins mais différents.

Un contrôle sur le diamètre des tuyaux des deux types a donné les résultats contenus dans le fichier **tubesGlouGlouGurging.csv**. Quelles conclusions en tirer ?

On demande de construire à partir de ces données présentées dans un fichier csv un data frame plus adapté aux types de test que l'on veut réaliser.

Remarque : comme la taille des échantillons n'est pas la même, il peut être intéressant de considérer

a) pour read.table le paramètre **na.strings=c("")**

b) pour tapply le paramètre **na.rm=T**

c) pour t.test **na.rm=T**

d) si on oublie ce genre de paramètre, on trouve le même résultat : justifier avec `getOption("na.action")`

1.3 On revient aux données concernant diverses mesures portant sur des Ormeaux (voir -ci-dessus). Pour rappel, les données sont disponibles dans le fichier **OrmeauxAbalones.csv**. Les variables utilisées figurent dans le rapport :

Name	Data Type	Meas.	Description
----	-----	-----	-----
Sex	nominal		M, F, and I (infant)
Length	continuous	mm	Longest shell measurement
Diameter	continuous	mm	perpendicular to length
Height	continuous	mm	with meat in shell
Whole weight	continuous	grams	whole abalone
Shucked weight	continuous	grams	weight of meat
Viscera weight	continuous	grams	gut weight (after bleeding)
Shell weight	continuous	grams	after being dried
Rings	integer		+1.5 gives the age in years

On demande de déterminer si

- ♦ la longueur des femelles adultes est significativement différente de celle des adultes mâles;
- ♦ la proportion longueur/diamètre des femelles adultes est significativement différente de celle des adultes mâles;
- ♦ quelles variables donnent des différences significatives entre les mâles et les femelles adultes.

2. Echantillons appariés

2.1 a. Un club de basket-ball souhaite évaluer si un stage d'une semaine peut avoir un impact sur la précision des enfants âgés de 10 ans dans la réussite de leurs tirs au panier. Pour ce faire, les performances des enfants sont mesurées en comptant le nombre de tirs réussis sur un total de 15 tentatives, à la fois au début et à la fin du stage.

Les résultats des tests individuels sont les suivants :

	E1	E2	E3	E4	E5	E6	E7	E8	E9	E10	E11	E12	E13	E14	E15	E16	E17	E18
J1	5	4	8	4	5	6	7	5	8	8	5	9	5	8	6	5	4	3
J6	8	7	6	9	5	8	4	5	7	8	5	5	6	4	6	4	8	7

Le club souhaite déterminer statistiquement si le stage a un effet significatif sur la précision des tirs au panier des enfants. Peut-on affirmer avec confiance que le stage a amélioré leurs performances ?"

2.2 b. Après avoir évalué l'impact du stage initial d'une semaine sur la précision des tirs au panier des enfants âgés de 10 ans, le club de basket-ball a poursuivi son suivi en proposant un programme d'entraînement régulier pendant une année entière. Ce programme consistait en des séances d'entraînement deux fois par semaine.

À la suite de cette année d'entraînement régulier, une nouvelle série de tests a été effectuée pour mesurer à nouveau le nombre de tirs réussis sur 15 tentatives pour chacun des enfants. Les résultats de ces tests après un an d'entraînement sont les suivants :

E1	E2	E3	E4	E5	E6	E7	E8	E9	E10	E11	E12	E13	E14	E15	E16	E17	E18
8	10	8	7	9	8	10	11	6	10	7	5	6	11	9	4	7	5

Le club souhaite maintenant déterminer si cette période d'entraînement régulier a eu un impact significatif sur les performances des enfants par rapport aux résultats initiaux du stage d'une semaine. Est-ce que cet entraînement continu a permis une amélioration statistiquement significative de la précision des tirs au panier des enfants par rapport aux résultats observés à la fin du stage initial ?"

2.2 La Faculté de Kinésithérapie de Boursoulavie a réalisé deux types de tests sur deux groupes - appelons-les "groupe témoin" et "groupe test". Il s'agit d'un test sur la vitesse de la balle lancée à la main (test Shot) et un test sur la résistance musculaire pour maintenir un poids à une hauteur minimale donnée (test KohLanta). Les résultats sont :

groupe témoin

sujet	Shot	KohLanta
PG	56	135.94
AD	79	91.41
HM	49	103
OB	79	57.47
RM	89	63.03

groupe test

sujet	Shot	KohLanta
MD	52	78.16
JM	91	88.91
LB	97	94.25
CW	102	108.15
AD	76	101.75

Le groupe test a ensuite suivi 50 séances de kiné endiablées. La question est évidemment de savoir si ces séances ont eu un impact significatif sur les performances des sujets lors des exercices physiques. Les nouveaux résultats à une deuxième séance de tests ont donné :

groupe témoin

sujet	Shot	KohLanta
PG	69	104.94
AD	77	163.59
HM	83	80.66
OB	74	60.21
RM	78	76.84

groupe test

sujet	Shot	KohLanta
MD	57	120.68
JM	99	109.84
LB	97	183.88
CW	84	109.93
AD	86	115.78

Quelles conclusions peut-on tirer de tout cela ?

T.P. Data n°7: Régression et corrélation

Objectifs : Maîtriser les analyses de régression-corrélation et savoir utiliser les procédures correspondantes de R.

1. La faculté agronomique de Bonnarie a mesuré les circonférences de cerisiers qui se sont déracinés après une tempête - il devenait alors très simple de mesurer leur hauteur. Le résultat se trouve dans le fichier csv "**trees.csv**".

Peut-on sur cette base considérer qu'il existe une relation entre la circonférence du tronc et la hauteur de l'arbre ?

2. On revient sur la culture du riz en Inde (fichier **RiceFarms.csv**).

a) Existe-t-il une relation entre la production brute et le coût des pesticides utilisés ?

b) Même question pour cette production mais pour le montant des salaires horaires (variable "wage");

c) Même question mais pour la quantité de phosphate déversé (variable "phosphate");

d) Même question mais pour le montant des salaires horaires couplé avec la quantité de phosphate déversé.

3. On revient à nouveau aux données portant sur l'ozone en Bretagne (fichier **etude-ozone-bretagne-2011.txt**). Peut-on affirmer que le maximum de concentration d'ozone observé dépend

- ♦ de la température observée à 15h ?
- ♦ de la nébulosité observée à midi ?
- ♦ des deux simultanément ?*
- ♦ de la teneur maximum en ozone observée la veille ?

4. On demande une étude des dépenses annuelles en jouets selon le nombre d'enfants (étude effectuée en Batracie, montants en milliers de pogns batraciens). Une enquête basique a donné les résultats suivants:

Nombre d'enfants	Montant des achats en jouets
1	7
2	3
3	1
4	2
5	6
6	8

Que peut-on prédire comme valeur pour 8 enfants selon le modèle qui aura été retenu ?

T.P. Data n°8: ANOVA 1**Objectifs** : Maîtriser la technique des procédures de l'ANOVA à 1 facteur

1. Un laboratoire d'analyses biochimiques s'intéresse au développement de la bactérie nommée *Houblonia orgeica* dans différents milieux (en fait, 5). On a doncensemencé avec une souche de cette bactérie des tubes contenant des échantillons de différents milieux. Le nombre estimé de bactéries qui s'y sont développées (en milliers) est repris dans le tableau suivant :

argile douce	compost	sauce anglaise	bolognaise	pâte à pain
11.70	13.87	15.31	12.55	10.72
12.24	13.20	16.20	11.05	13.28
13.20	11.45	15.42	11.80	13.73
9.82	11.02	14.04	12.31	11.77
13.10	9.82	12.99	10.26	10.91
11.31	13.38	14.15	10.58	10.31
10.15	15.59	14.66	12.27	11.02
11.23	13.39	15.11	11.54	9.88
11.43	12.28	13.77	10.83	11.60
32.13	15.34	14.11	11.76	11.63
11.67		12.54	11.01	
13.34			10.92	

Au seuil de 5 %, peut-on considérer que le milieu de culture possède une influence sur la croissance de la bactérie étudiée ?

Les hypothèses classiques d'une analyse de variance semblent-elles vérifiées ?

Calculer manuellement au moyen d'Excel la valeur de la statistique de Fisher.

2. Le fichier **RiceFarms.csv** contient des données sur la culture du riz en Inde. On peut remarquer plus particulièrement les variables

- ◆ id : un simple identifiant pour chaque exploitation agricole qui a été étudiée
- ◆ size : la taille de l'exploitation en hectares
- ◆ status : le type d'exploitation, c'est-à-dire le fait que l'exploitation est uniquement cultivée par le propriétaire ("owner") ou par sous-traitance par des métayers ("share") ou un mélange des deux ("mixed")
- ◆ varieties : le type de riz, soit variétés traditionnelles exclusivement ("trad"), variétés à haute valeur de rendement par engrais et/ou OGM ("high") ou un mélange des deux ("mixed")
- ◆ goutput : production brute en kg par hectare
- ◆ noutput : production nette (donc en tenant compte des frais de culture, payés en riz) en kg
- ◆ pesticide : coût des pesticides en roupies
- ◆ region : région de l'exploitation ('wargabinangun', 'langan', 'gunungwangi', 'malausma', 'sukaambit', 'ciwangi')

- a) Observe-t-on des différences significatives entre régions en ce qui concerne la production brute par hectare ?
- b) Même question pour les pesticides.
- c) Observe-t-on des différences significatives entre régions en ce qui concerne le type d'exploitation ?

Ne pas oublier d'échantillonner de manière représentative.

3. On revient à nouveau aux données portant sur l'ozone en Bretagne (fichier **etude-ozone-bretagne-2011.txt**). Peut-on affirmer que le maximum de concentration d'ozone observé dépend

- ◆ du fait que les mesures sont prises par temps pluvieux ou pas ?
- ◆ de l'orientation du vent lors de la prise de mesures ?

T.P. Data n°9: Les tests non paramétriques

Objectifs : Maîtriser les principes et la technique des procédures du chi-carré et de la corrélation de rangs sous R

1. Le test du chi-carré

1. En vue de gérer de manière optimale ses stocks de poches de sang, la clinique "Bonheur et santé" réalise une vaste enquête pour déterminer si, parmi les donneurs de sang réguliers de la clinique, le groupe sanguin est lié au sexe. Les résultats sont les suivants :

	hommes	femmes
AB	25	15
A	215	207
O	200	194
B	60	60

Le rapport est-il si évident ?

2. On revient au rapport sur les salaires bruts en 2013 de 3000 travailleurs masculins des états du centre-est des U.S.A. (données disponibles dans le fichier **Wage.csv**). On profite de ces chiffres pour détecter une éventuelle dépendance entre le groupe racial des travailleurs et leur niveau d'éducation. Que conclure ?