



Statistique : Chapitre 4

1.1 La loi normale générale

La distribution des effectifs (ou des fréquences) de nombreuses variables statistiques suit une courbe en forme de cloche.

Cette loi est connue sous le nom de loi normale ou loi de Gauss ou loi de Laplace-Gauss



Pierre Simon de Laplace
(1749 – 1827)
mathématicien,
astronome et
physicien
français



Johann Carl Friedrich Gauss
(1777 – 1855)
mathématicien,
astronome et
physicien
allemand

moyenne de la population

$$e^{-\frac{x^2}{2}}$$

L'esprit de ce document est d'expliquer brièvement ce qu'est la loi normale, également appelée loi de Gauss ou loi de Laplace-Gauss.

La loi normale est une distribution statistique en forme de cloche symétrique autour d'une valeur centrale appelée la moyenne (notée μ). Cette distribution est très répandue en statistique, car beaucoup de phénomènes naturels ou sociaux suivent une répartition autour d'une moyenne avec une concentration élevée au centre et une diminution progressive en s'éloignant de cette moyenne.

Quelques points essentiels à retenir sur l'esprit de la loi normale :

- Elle est caractérisée principalement par deux paramètres :
 - la moyenne (μ), qui indique le centre de la distribution.
 - l'écart-type (σ), qui mesure la dispersion ou l'étalement des données autour de cette moyenne.
- Graphiquement, elle se représente par une courbe symétrique en forme de cloche.
- Pierre Simon de Laplace et Carl Friedrich Gauss, deux célèbres mathématiciens, ont contribué significativement à son développement théorique.
- Cette loi permet d'étudier des phénomènes variés (taille, poids, notes d'examens, erreurs de mesure, etc.), où la majorité des observations se concentrent autour d'une valeur centrale, avec une décroissance rapide des fréquences vers les extrémités.

En résumé, l'esprit de ce document est d'introduire simplement le concept fondamental de loi normale dans un contexte pédagogique.

La fonction

$$e^{-\frac{x^2}{2}}$$

est en effet une première approximation de la loi normale standard. La loi normale standard complète est définie par la fonction densité de probabilité suivante :

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

Pourquoi cette différence ?


- La fonction simplifiée $e^{-\frac{x^2}{2}}$ décrit uniquement la forme générale (en cloche) de la distribution.
- Le facteur $\frac{1}{\sqrt{2\pi}} \approx 0,3989$ est une constante de normalisation qui permet de s'assurer que la surface totale sous la courbe vaut exactement 1, ce qui est nécessaire pour une densité de probabilité.

Ainsi, effectivement, $e^{-\frac{x^2}{2}}$ est une approximation visuelle utile pour comprendre la forme générale de la loi normale, mais la vraie fonction densité de probabilité nécessite la constante $\frac{1}{\sqrt{2\pi}}$.

```

> f<- function(x) {exp(-x*x/2)}
> f(0)
[1] 1
> integrate(f,-100,100)
2.506628 with absolute error < 8.1e-07
> sqrt(2*pi)
[1] 2.506628
> integrate(f,-Inf,Inf)
2.506628 with absolute error < 0.00023

```



$$f(X) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}X^2}$$

où

$$-\infty < X < +\infty$$


C'est ce qui est illustré ici

- La fonction définie en R comme $f(x) = e^{-\frac{x^2}{2}}$ est intégrée sur l'intervalle $(-\infty, +\infty)$. Le résultat obtenu est 2.506628, qui correspond précisément à la valeur $\sqrt{2\pi} \approx 2.506628$.
- Cela démontre explicitement pourquoi on doit ajouter la constante $\frac{1}{\sqrt{2\pi}}$ devant la fonction pour la transformer en densité de probabilité. En effet, une densité de probabilité doit obligatoirement avoir une intégrale égale à 1 sur tout le domaine $(-\infty, +\infty)$.
- Ainsi, la fonction finale (densité de la loi normale standardisée) devient bien :

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

Ce schéma confirme clairement ce que nous avons discuté précédemment.

```
> fd<- function(x) {1/sqrt(2*pi)*exp(-x*x/2)}
> f(0)
[1] 1
> fd(0)
[1] 0.3989423
> integrate(fd,-Inf,Inf)
1 with absolute error < 9.4e-05
```



Si $\mu \neq 0$ et/ou $\sigma \neq 1$:

$$f(X) = \frac{1}{\sigma \cdot \sqrt{2\pi}} \cdot e^{-\frac{1}{2} \left(\frac{X-\mu}{\sigma} \right)^2}$$

où

$$-\infty < X < +\infty$$

$$E(X) = \mu$$

$$s(X) = \sigma$$

$$L(X) = N(\mu; \sigma)$$

📌 Explication détaillée :

① La fonction définie en R (encadré vert)

La fonction :

$$fd(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

est définie directement en langage R (code vert).

- Elle est évaluée en 0, et on obtient environ 0.3989423, qui est précisément la valeur de la densité de probabilité normale standard en zéro.
- L'intégrale de cette fonction (calculée numériquement de $-\infty$ à $+\infty$) est égale à 1, confirmant bien qu'elle est une véritable densité de probabilité.

② La représentation graphique (courbes à droite)

- On a deux courbes représentées :
 - En bleu, la courbe correspondant à la densité normale standard :

$$\mu = 0, \quad \sigma = 1$$

- En vert, une autre densité normale avec un écart-type différent (plus grand), ce qui donne une courbe plus plate, plus étalée.
- La valeur de σ (sigma) définit l'étalement de la courbe :
 - σ petit $\rightarrow$ courbe étroite (données peu dispersées autour de la moyenne).
 - σ grand $\rightarrow$ courbe large (données très dispersées).

③ La généralisation (cadre jaune)

La densité normale complète (avec une moyenne μ quelconque et un écart-type σ quelconque) est donnée par :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Cette expression généralise la loi normale standard :

- Quand $\mu = 0$ et $\sigma = 1$, on retrouve exactement la densité normale standard précédente :

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

④ Signification statistique (encadré blanc en bas)

- $E(X) = \mu$ signifie que l'espérance (la moyenne théorique de la variable aléatoire) est égale à μ .
- $s(X) = \sigma$ signifie que l'écart-type (la dispersion autour de la moyenne) est égal à σ .

La notation générale est :

$$L(X) = N(\mu; \sigma)$$

qui indique clairement que la loi suivie par la variable aléatoire X est une loi normale de moyenne μ et d'écart-type σ .

En résumé :

Ce document présente :


- La loi normale standard (centrée réduite, $\mu = 0$, $\sigma = 1$).
- La loi normale généralisée (μ et σ quelconques).
- Les calculs numériques montrant que l'intégrale totale d'une densité normale vaut bien 1.
- La signification intuitive des paramètres μ et σ .

Ce sont précisément ces éléments qui sont illustrés clairement ici.

R: `pnorm()`, `qnorm()`, `rnorm()`, `dnorm()`

```
> pnorm(2)
[1] 0.9772499
> qnorm(0.95)
[1] 1.644854
> qnorm(0.99)
[1] 2.326348
> qnorm(0.975)
[1] 1.959964
> qnorm(0.025)
[1] -1.959964
```

```
> pnorm(650, 895, 35)
[1] 1.279813e-12
> pnorm(830, 895, 35)
[1] 0.03164542
> pnorm(830, 895, 35, lower.tail=F)
[1] 0.9683546
> qnorm(0.9, 895, 35)
[1] 939.8543
> qnorm(0.9, 895, 35, lower.tail=F)
[1] 850.1457
```



🚩 Objectif de la page :

Cette page explique les principales fonctions statistiques disponibles dans le logiciel R associées à la loi normale :

- `pnorm()`
- `qnorm()`
- `rnorm()`
- `dnorm()`

(La page illustre principalement `pnorm()` et `qnorm()`.)

■ 1. Les fonctions statistiques en R :

▶ `pnorm(x, μ, σ)`

Cette fonction calcule la probabilité cumulée d'une distribution normale, c'est-à-dire :

$$P(X \leq x)$$

Par exemple :

```
R                                                                    Copy Edit

pnorm(2)
```

donne 0.9772499. Cela signifie :

- $P(X \leq 2) = 97.72499\%$ pour une loi normale standard ($\mu = 0, \sigma = 1$).

Visuellement :

Cela représente l'aire sous la courbe de la loi normale standard à gauche du point $x = 2$.


► `qnorm(p, $\mu$ , $\sigma$ )`

Cette fonction fait l'inverse : elle donne la valeur quantile correspondant à une probabilité donnée.

Autrement dit, elle répond à la question :

« Quelle valeur x correspond à une aire (probabilité) donnée sous la courbe ? »

Par exemple :



donne 1.644854, cela signifie :

- 95% des données se trouvent en dessous de 1.644854 pour une loi normale standard.

On voit ainsi différents exemples :

- `qnorm(0.975)` → 1.959964
- `qnorm(0.025)` → -1.959964 (symétrie par rapport à zéro, intervalle à 95%)

Ces valeurs (1.96) sont très célèbres en statistiques, car elles correspondent aux seuils pour un intervalle de confiance à 95%.

■ 2. Exemple concret (deuxième cadre vert)

On considère une loi normale **non standard**, avec une moyenne $\mu = 895$ et un écart-type $\sigma = 35$. La notation est :

$$X \sim N(895; 35)$$

Exemples :

- `pnorm(650, 895, 35)`
 - Donne une probabilité quasi nulle (`1.279813e-12`), ce qui signifie qu'il est quasiment impossible d'obtenir une valeur aussi petite (650), très éloignée en dessous de la moyenne (895).
- `pnorm(830, 895, 35)`
 - Donne `0.03164542`, donc environ **3,16%** des valeurs sont inférieures à 830.
- `pnorm(830, 895, 35, lower.tail=F)`
 - Donne la probabilité à droite de 830, soit `0.9683546`, ce qui signifie qu'environ **96,84%** des valeurs sont supérieures à 830.

Le paramètre `lower.tail=F` inverse la direction de l'aire calculée (vers la droite au lieu de la gauche).

- `qnorm(0.9, 895, 35)`
 - Donne la valeur quantile correspondant à 90% (`939.8543`) :
Cela signifie que 90% des données sont inférieures à 939.8543.
- `qnorm(0.9, 895, 35, lower.tail=F)`
 - Donne le quantile inversé (`850.1457`) :
90% des valeurs sont supérieures à 850.1457 (10% sont en dessous).

3. Illustration graphique (à droite)

L'image représente graphiquement la loi normale avec la fameuse règle empirique des 68-95-99,7% :

- 68,26% des valeurs sont comprises entre $\pm 1\sigma$ autour de la moyenne μ .
- 95,44% sont comprises entre $\pm 2\sigma$.
- 99,74% sont comprises entre $\pm 3\sigma$.

Cela illustre pourquoi les quantiles ± 1.96 (environ $\pm 2\sigma$) apparaissent fréquemment : ils définissent précisément les intervalles à 95% autour de la moyenne.

Synthèse rapide :


- `pnorm()` donne des probabilités (aires sous la courbe vers la gauche).
- `qnorm()` donne des valeurs quantiles à partir de probabilités.
- `lower.tail=F` permet d'inverser le sens des probabilités calculées.
- La représentation graphique rappelle la signification des écarts-types et quantiles couramment utilisés.

Cette page résume très clairement comment manipuler les fonctions R pour étudier une loi normale, visualiser ses propriétés et répondre à des questions pratiques en statistiques.

2. La loi de Student

$$f(t) = c \cdot \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

Le paramètre ν est appelé le nombre de **degrés de liberté** [*degrees of freedom*]



William Sealy Gosset
(1876-1937)
statisticien britannique

$$L(X) = St(\nu)$$

La distribution est symétrique par rapport à l'origine et ressemble à la distribution normale centrée réduite mais elle est un peu plus aplatie.

Sujet de la page : la loi de Student

La loi de Student est une distribution statistique très utilisée dans les tests d'hypothèses lorsque l'écart-type de la population est inconnu et que l'on dispose d'un petit échantillon.

1. La formule mathématique (cadre jaune)

La densité de probabilité d'une variable suivant une loi de Student est donnée par :

$$f(t) = c \cdot \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

- t est la variable aléatoire considérée.
- c est une constante de normalisation, dépendant du nombre de degrés de liberté ν .
- Le paramètre ν (lettre grecque « nu ») représente les **degrés de liberté** (*degrees of freedom*).

Cette formule définit précisément la forme de la distribution de Student.

2. La notion de degrés de liberté ν

- Le paramètre ν (nu) est crucial : il définit la forme exacte de la courbe.
- Plus le nombre de degrés de liberté est faible, plus la distribution est étalée avec des queues épaisses (elle admet des valeurs extrêmes avec une probabilité plus grande).
- Lorsque ν augmente, la loi de Student devient de plus en plus proche de la loi normale centrée réduite.

Typiquement, en statistiques pratiques :

- Le nombre de degrés de liberté est souvent :
 - $\nu = n - 1$, avec n la taille de l'échantillon étudié.

3. Graphique illustratif (centre droit)

Le graphique montre clairement comment la loi de Student varie selon les degrés de liberté :

- **Courbe « loi normale » :**
 - Elle est centrée et réduite ($\mu = 0, \sigma = 1$).
 - Elle est utilisée comme référence.
- **Courbes « loi de Student »** (pour différentes valeurs de ν) :
 - Plus le paramètre ν est petit (ex : $\nu = 1$), plus la courbe est **aplatie**, et ses extrémités (queues) sont épaisses.
 - À mesure que ν augmente (ex : $\nu = 4$), la courbe de Student se rapproche de celle de la loi normale (elle devient plus pointue et les queues plus minces).

Cette représentation visuelle permet d'intuitionner l'effet concret du nombre de degrés de liberté sur la distribution.

4. Caractéristiques importantes

- **Symétrie :**
La distribution de Student est toujours symétrique autour de zéro (centrée).
- **Forme générale :**
Elle ressemble beaucoup à la loi normale, mais avec une dispersion légèrement plus importante.
Cette caractéristique rend la loi de Student particulièrement adaptée lorsqu'on doit tenir compte de l'incertitude liée à une taille d'échantillon réduite.
- **Notation statistique classique :**

$$L(X) = St(\nu)$$

Cela signifie simplement que la variable aléatoire X suit une loi de Student avec un paramètre ν .

5. Historique : William Sealy Gosset

- Sur la droite figure une photo de William Sealy Gosset, statisticien britannique (1876–1937).
- Il a créé cette loi sous le pseudonyme « Student », d'où le nom de « loi de Student ». Gosset travaillait pour la brasserie Guinness et avait développé cette loi pour contrôler la qualité à partir de petits échantillons.

En résumé clair :

Cette page explique la loi de Student, une distribution symétrique utilisée principalement quand :

- La taille de l'échantillon est petite.
- L'écart-type de la population étudiée est inconnu.

Elle montre clairement la formule mathématique, explique le concept crucial des degrés de liberté, et illustre graphiquement les différences avec la loi normale standard.

Voilà l'esprit et le contenu précis de cette page !

Que signifie exactement la variable aléatoire t ?

Dans le cadre de la loi de Student, la variable t correspond à une **valeur standardisée issue d'un échantillon**, c'est-à-dire une valeur obtenue en comparant la moyenne d'un échantillon à une moyenne théorique (ou population), en tenant compte de l'incertitude sur l'écart-type réel de la population.

Plus concrètement, on utilise typiquement la loi de Student lorsqu'on veut tester des hypothèses sur la moyenne d'une population à partir d'un petit échantillon dont on ne connaît **pas l'écart-type réel** (σ), et qu'on doit donc l'estimer à partir de l'échantillon.

Formule concrète de la variable t :

La variable aléatoire t utilisée dans un test statistique est donnée par :

$$t = \frac{\bar{x} - \mu}{s / \sqrt{n}}$$

- $\bar{x}$: moyenne observée dans ton échantillon.
- μ : moyenne théorique de référence que tu veux tester.
- s : écart-type estimé à partir de l'échantillon.
- n : taille de l'échantillon.

Cette valeur standardisée t mesure simplement **combien d'écarts-types ton résultat est éloigné de la moyenne attendue** selon l'hypothèse.

Exemple concret très simple :

Suppose que tu veuilles vérifier si le poids moyen d'une certaine variété de pommes est bien de 200 grammes comme affirmé par un producteur. Tu prélèves alors un petit échantillon de pommes pour tester cette affirmation.

Données de ton échantillon :

- Tu prends un échantillon de taille $n = 5$ pommes.
- Les poids (en grammes) obtenus sont :

195, 203, 198, 207, 196

Tu souhaites donc tester :

- $H_0 : \mu = 200$ grammes (l'affirmation du producteur est vraie).
- contre
- $H_1 : \mu \neq 200$ grammes (le poids moyen diffère de 200 grammes).

Calcul rapide :

1. Calcul de la moyenne observée ($\bar{x}$):

$$\bar{x} = \frac{195 + 203 + 198 + 207 + 196}{5} = \frac{999}{5} = 199.8 \text{ grammes}$$

2. Calcul de l'écart-type estimé (s):

Formule (estimation non biaisée) :

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}$$

Ici, supposons que tu obtiens (après calcul précis) environ :

$$s \approx 4.76 \text{ grammes}$$

3. Calcul du t -statistique :

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}} = \frac{199.8 - 200}{4.76/\sqrt{5}} \approx -0.094$$

Cette valeur est la fameuse variable aléatoire t que tu compareras aux valeurs critiques issues d'une loi de Student à $n - 1 = 4$ degrés de liberté pour déterminer si ton résultat est significativement différent de 200 ou non.



Interprétation concrète du résultat :

- La valeur $t = -0.094$ signifie simplement que ta moyenne observée (199.8 g) est très proche de 200 g, à seulement **0.094 écart-type** de la moyenne théorique.
 - En consultant les valeurs critiques de la loi de Student avec 4 degrés de liberté, tu constaterais probablement que ce résultat **n'est pas statistiquement significatif**.
 - Donc, tu n'as pas suffisamment de preuve pour rejeter l'affirmation du producteur (200 g).
-



Pourquoi préférer ici la loi de Student à la loi normale ?

- Parce que tu disposes d'un petit échantillon ($n = 5$ ici), l'écart-type réel de la population est inconnu et estimé.
 - Dans ce contexte, la loi de Student, qui tient compte explicitement de cette incertitude supplémentaire (par l'estimation de l'écart-type), est préférée à la loi normale.
 - Avec un grand échantillon ($n > 30$), tu aurais pu utiliser la loi normale approximativement sans trop d'erreur, mais pour un petit échantillon, c'est la loi de Student qui est pertinente.
-



En résumé clair :

- La variable t mesure l'écart standardisé entre la moyenne observée d'un échantillon et une moyenne théorique.
 - La loi de Student est indispensable quand l'écart-type de la population est inconnu, surtout avec de petits échantillons.
 - L'exemple concret (test sur le poids de pomme ) montre clairement la logique pratique de son utilisation.
-

- Elle est toujours associée à une somme de carrés; le plus souvent, il s'agit de **carrés d'écarts**.

Le nombre de degrés de liberté est le nombre d'écarts indépendants utilisés dans la somme des carrés, c'est-à-dire le nombre d'écarts nécessaires diminué du nombre de restrictions sur ces écarts; on peut aussi dire que c'est le nombre d'écarts nécessaires diminué du nombre de paramètres que l'on doit estimer pour effectuer le calcul de ces écarts.

- On peut démontrer que lorsque le nombre de degrés de liberté augmente, on approche de plus en plus d'une loi normale centrée réduite.

$$E(t) = 0 \quad \text{et} \quad s(t) = \sqrt{\frac{v}{v-2}} \quad (v > 2)$$

■ 1. L'idée générale : la notion de « carrés d'écarts »

Quand tu utilises la loi de Student, tu travailles souvent avec des « carrés d'écarts ». Concrètement, cela signifie que tu calcules une somme de termes du type :

$$(x_i - \bar{x})^2$$

Ce sont des carrés des écarts (différences) entre chaque observation et la moyenne observée. La loi de Student est donc toujours associée à ce type de calcul.

■ 2. Que sont précisément les degrés de liberté (ν) ?

La définition (soulignée sur ton document) est cruciale :

Le nombre de degrés de liberté est le nombre d'écarts indépendants utilisés dans la somme des carrés, c'est-à-dire :

- "le nombre d'écarts nécessaires diminué du nombre de restrictions sur ces écarts,"
- "ou, dit autrement, c'est le nombre d'écarts nécessaires diminué du nombre de paramètres que tu dois estimer avant de calculer ces écarts."

Pour comprendre cela simplement, prenons un exemple concret :

Exemple simple d'explication :

Imaginons que tu disposes de 5 données :

$$5, \quad 7, \quad 9, \quad 8, \quad 6$$

- **Étape 1** : tu calcules la moyenne :

$$\bar{x} = \frac{5 + 7 + 9 + 8 + 6}{5} = 7$$

- **Étape 2** : Tu calcules les écarts à cette moyenne :

$$5 - 7 = -2, \quad 7 - 7 = 0, \quad 9 - 7 = 2, \quad 8 - 7 = 1, \quad 6 - 7 = -1$$

Ces 5 écarts ne sont pas tous indépendants : si tu en connais 4, tu peux obligatoirement déterminer le cinquième. Pourquoi ? Parce que leur somme doit toujours être égale à zéro :

$$(-2) + (0) + (2) + (1) + (-1) = 0$$

- Si tu connaissais seulement 4 écarts : (-2, 0, 2, 1), tu peux immédiatement deviner le cinquième (-1), car leur somme est contrainte à zéro.

Donc : tu as ici 4 degrés de liberté seulement (5 données – 1 paramètre estimé, la moyenne).

3. Pourquoi doit-on retirer le nombre de paramètres estimés ?

Chaque paramètre que tu estimes à partir des données (ici la moyenne) impose une restriction à tes données. Ainsi :

- Si tu estimes 1 paramètre (la moyenne), tu perds 1 degré de liberté.
- Si tu estimes 2 paramètres (par exemple, moyenne et pente dans une régression), tu perds 2 degrés de liberté, etc.

Autrement dit, chaque paramètre estimé réduit ton « libre choix » (ou liberté) d'une donnée supplémentaire.

4. Le lien avec la loi normale :

Quand le nombre de degrés de liberté (ν) augmente, la loi de Student devient très proche d'une loi normale centrée réduite (standard).

Formellement, on peut montrer que la loi de Student a :

- une espérance égale à 0 :

$$E(t) = 0$$

- un écart-type (standard deviation) donné par :

$$s(t) = \sqrt{\frac{\nu}{\nu - 2}} \quad (\nu > 2)$$

Ce résultat signifie :

- Quand ν est grand (par exemple $\nu = 30$ ou plus), $\frac{\nu}{\nu - 2} \approx 1$, la loi de Student ressemble quasiment à une loi normale standard ($\mu = 0, \sigma = 1$).
- Si ν est petit (comme 3 ou 4), l'écart-type est sensiblement plus grand que 1, ce qui correspond à une distribution plus étalée que la normale.

En résumé très clair :

- **Carrés d'écarts** : Utilisés pour calculer la variance ou pour tester des hypothèses sur une moyenne.
- **Degrés de liberté** : Nombre de valeurs indépendantes disponibles une fois soustraits les paramètres estimés à partir des données.
- **Lien avec la loi normale** : Plus les degrés de liberté sont élevés, plus la loi de Student ressemble à une loi normale standard.

Cette page explique de façon précise pourquoi le nombre de degrés de liberté est important et comment il impacte concrètement la forme de la loi utilisée en statistiques.

Les valeurs de t sont tabulées dans une table admettant des degrés de liberté allant jusqu'à 90. En pratique, on repasse à la loi normale dès que le nombre de degrés de liberté atteint 30.

R: pt(), qt(), rt(), dt()

En fait, une variable aléatoire t qui suit une loi de Student peut être définie à partir :

- d'une variable normale centrée réduite;
- d'une variable suivant une loi du khi-deux (khi carré) à ν degrés de liberté car elle est alors définie comme le rapport :

$$t = \frac{Z}{\sqrt{\frac{\chi^2}{\nu}}}$$

1. Utilisation pratique (haut de la page)

Cette partie du document précise un point très important sur l'utilisation concrète de la loi de Student :

- Les valeurs critiques (valeurs t) d'une loi de Student sont historiquement trouvées dans des tables statistiques.
- Ces tables existent souvent pour un nombre de degrés de liberté allant jusqu'à environ **90** degrés de liberté.
- Mais en pratique, dès que le nombre de degrés de liberté (ν) atteint environ **30**, la différence entre la loi de Student et la loi normale devient tellement minime qu'on utilise simplement la loi normale à la place, par commodité.

En résumé :

- Pour $\nu < 30$, utiliser une table ou la loi de Student.
- Pour $\nu \geq 30$, la loi normale standard est une très bonne approximation.

2. Fonctions en langage R (encadré bleu clair)

En R, pour travailler avec la loi de Student, tu peux utiliser les fonctions suivantes :

- `pt()` : Calcule la probabilité cumulée sous la loi de Student.
Exemple : `pt(1.5, df=10)` donne $P(T \leq 1.5)$ avec 10 degrés de liberté.
- `qt()` : Trouve le quantile associé à une probabilité donnée.
Exemple : `qt(0.975, df=10)` donne la valeur critique pour un intervalle à 95%.
- `rt()` : Génère des nombres aléatoires suivant une loi de Student.
Exemple : `rt(100, df=10)` donne 100 observations aléatoires selon Student à 10 degrés de liberté.
- `dt()` : Calcule la valeur de la densité (hauteur de la courbe).
Exemple : `dt(0, df=10)` donne la densité au point $t = 0$.

Ces fonctions facilitent grandement les calculs statistiques impliquant la loi de Student.

3. Lien entre loi de Student, loi normale et loi du khi-deux (partie basse)

Le document précise ici une **relation fondamentale** entre ces trois distributions statistiques importantes :

Une variable aléatoire suivant une loi de Student (t) peut être définie à partir :

- d'une variable aléatoire suivant une loi normale centrée réduite (Z),
- et d'une autre variable aléatoire indépendante suivant une loi du khi-deux (χ^2) à ν degrés de liberté.

Formule explicite : (encadré bleu)

$$t = \frac{Z}{\sqrt{\frac{\chi^2}{\nu}}}$$

Où :

- Z est une variable suivant une loi normale centrée réduite ($N(0; 1)$).
- χ^2 est une variable suivant une loi du khi-deux indépendante à ν degrés de liberté.
- ν est le nombre de degrés de liberté.

Cette définition signifie intuitivement :

- La loi de Student combine deux types d'incertitudes :
 - Celle venant d'une loi normale (l'incertitude aléatoire classique).
 - Celle venant d'une loi du khi-deux (incertitude due à l'estimation de la variance).

Ainsi, la loi de Student peut être vue comme une « loi normale corrigée » qui prend en compte l'incertitude sur l'estimation de la variance.

Pourquoi cette définition est-elle utile ?

Cette définition :

- Explique clairement pourquoi la loi de Student est utilisée lorsqu'on ne connaît pas la variance réelle (et qu'on doit l'estimer à partir des données).
 - Permet d'utiliser des techniques mathématiques pour démontrer les propriétés théoriques de la loi de Student à partir des propriétés connues des lois normale et du khi-deux.
-

Synthèse finale claire :

- **Pratiquement :**
 - Pour des degrés de liberté ≥ 30 , on utilise la loi normale.
 - Pour des calculs précis, on utilise les fonctions R (`pt()` , `qt()` , `rt()` , `dt()`).
- **Théoriquement :**
 - La loi de Student est définie à partir d'une loi normale centrée réduite et d'une loi du khi-deux, ce qui la rend très pertinente pour modéliser l'incertitude due à la variance estimée sur de petits échantillons.