



Haute Ecole de la Province de Liège

Techniques avancées de gestion des données

Bases de données avancées et XML

Leçon 10 : Bases de données distribuées,
Entrepôts de données et jobs

Samuel Hiard


Année académique 2023-2024

Agenda

- Bases de données distribuées
 - Introduction
 - Concepts et caractéristiques
 - Architecture
 - Fragmentation
 - Transparence
 - En pratique : DBLink

Première approche

- Plusieurs BDD locales reliées en réseau



- Répartition physique des données
- Corrélation logique
- BDD Distribuée? Pas vraiment

Gestion des applications

- Pour parler de bases de données distribuées, il faut utiliser le concept d'applications.
- Applications uniquement locales
 - chaque BDD ne voit qu'elle-même
 - Les applications désirant accéder aux données doivent se connecter indépendamment aux différentes bases de données

→ Ensemble de bases de données locales
- Au moins une application globale
 - Les BDD ont conscience les unes des autres
 - Il est possible, pour une application, de ne se connecter qu'à une seule BDD
 - Cette BDD peut contacter les autres pour récupérer l'info nécessaire

→ BDD distribuée

Définition

- Pour résumer :
 - Une base de données distribuées est une collection de données réparties sur plusieurs machines (sites) reliées en réseau.
 - Chaque site a des capacités de traitement autonome et peut proposer des applications locales.
 - Chaque site prend part à l'exécution d'au moins une application qui est capable d'accéder aux données de plusieurs sites au moyen du réseau.


Homo/Hétéro-généité

- BDD distribuée homogène
 - Composée de bases de données qui font tourner le même SGBD
 - Mais les systèmes d'exploitation peuvent être différents
- BDD distribuée hétérogène
 - Plusieurs SGBD coexistent dans l'intégration
 - 2 niveaux:
 - Même fournisseur, mais différentes versions
 - Ex : Oracle 11g et Oracle 19c
 - Fournisseurs différents
 - Ex : Oracle 19c et MySQL 8.0

Distribution/Réplication


- Base De Données Distribuée ou répliquée?
- BDD purement distribuée
 - Le système gère une seule copie de chaque donnée ou objet.
 - Il utilise des transactions distribuées pour accéder à la fois au contenu local et distant
 - Il modifie la base de données local en temps réel
- BDD répliquée
 - Se réfère à l'opération de copier et maintenir les objets de la base de données dans plusieurs bases de données appartenant au système distribué
 - Chaque donnée/objet peut donc avoir plusieurs copies

Conception ascendante ou descendante




- Ascendante
 - Conception de la BDD distribuée à partir de bases de données existantes
 - On crée le schéma global à partir des schémas locaux
 - La distribution est préexistante et doit être gérée
 - Souvent utilisé dans des BDD hétérogènes
 - Donc, avec généralement un besoin de réconciliation syntaxique/sémantique

Conception ascendante ou descendante (2)




- Descendant
 - Utilisé lors de la construction d'une nouvelle base de données
 - Crée d'abord un schéma global, les différentes entités sont ensuite distribuées sur les sites
 - Commence à partir d'une étape « nouvelle » orientée vers la performance et la disponibilité
 - Plutôt rare (jusqu'à la fin des années 90) et pas très compliqué à mettre en œuvre
 - Produit un système homogène

Architecture




Au niveau des relations (tables)



Fragmentation

- Horizontale vs verticale



- Fragmentation hybride (verticale + horizontale) possible


Fragmentation horizontale

- Partitionnement de la relation par rapport à ses tuples
- Décomposition à l'aide d'une SELECTION
- Exemple

```
SELECT *  
FROM student WHERE site = 'BXL';
```



```
SELECT *  
FROM student WHERE site = 'Liege';
```



- Reconstruction : UNION

Fragmentation verticale


- Partitionnement de la relation par rapport à ses attributs
- Décomposition à l'aide d'une PROJECTION
- Exemple

SELECT
IDEtud, name, firstname FROM student;



BD1

SELECT
IDEtud, year, institute FROM student;




BD2

- Reconstruction : JOIN sur les attributs communs


Transparence

- 4 niveaux de transparence
 - Transparence de fragmentation
 - Le développeur travaille uniquement avec les relations globales
 - Le SGBD connaît la répartition en fragments et modifie la requête
 - Transparence de localisation
 - Le développeur a connaissance des fragments, mais pas forcément de leur emplacement
 - Le SGBD va indiquer, pour chaque fragment, où il se situe
 - Transparence de correspondance locale
 - Le développeur travaille sur les fragments et leur localisation
 - Le SGBD effectue les transferts réseaux et les connections
 - Pas de transparence
 - Le développeur doit tout faire (y compris se connecter à chaque base de données individuellement)

Architecture



Exemple de transparence



Lecture vs Ecriture

- Lecture
 - Assez simple à utiliser
 - L'information à récupérer se trouve grâce aux schémas de fragmentation et de localisation
- Ecriture
 - Une insertion ou une modification peut fortement perturber le système
 - Modification dans un fragment = modification dans toutes les autres copies de ce fragment
 - Utilisation d'un déclencheur possible
 - Certains cas encore plus difficiles
 - Fragmentation horizontale en fonction de l'attribut « Localité »
 - Un étudiant change d'adresse
 - Il faut qu'il change de fragment, et donc potentiellement de BD aussi!

Réplication et distribution en pratique

- Dans un système d'information distribué avec plusieurs bases de données, on gère les données en utilisant un mélange de
 - Partage ou distribution pure : Aucune donnée n'est dupliquée
 - Réplication : Des données sont copiées
- Dans les deux cas, on utilise des *DB Links* (des liens de bases de données) pour permettre le transfert de données d'un schéma vers un autre.

Qu'est-ce qu'un DB Link?

- C'est un objet SQL Oracle dans un schéma sur une base de données locale.
- Il permet l'accès aux objets dans un schéma distant, généralement sur une base de données distante
 - Peut également fonctionner en local, même si l'intérêt est limité
- A besoin des privilèges systèmes (avec GRANT)
 - CREATE DATABASE LINK sur la BD locale
 - CREATE SESSION sur la BD distante

DB Link : Syntaxe

```
CREATE DATABASE LINK <db link name>  
CONNECT TO <user> IDENTIFIED BY <password>  
USING '<connect string>';
```


Nom de service (connect_string)

- Dans TNSNames.ora

```
nom_alias=
  (DESCRIPTION=
    (ADDRESS_LIST=
      (ADDRESS=(PROTOCOL=TCP)(HOST=adresse distante)
        (PORT=port distant)
      )
    )
    (CONNECT_DATA=
      (SERVICE_NAME=distante_db)
    )
  )
```

Graphiquement

create_database_link::=



Description of the illustration [create_database_link.gif](#)

dblink_authentication ::=



Description of the illustration [dblink_authentication.gif](#)

Exemple complet

- Dans TNSName.ora

```
db2=
  (DESCRIPTION=
    (ADDRESS_LIST=
      (ADDRESS=(PROTOCOL=TCP)(HOST=localhost)(PORT=1521) )
    )
    (CONNECT_DATA= (SERVER=DEDICATED)
                  (SERVICE_NAME=xe) )
  )
```

- Puis, en ligne de commande

```
CREATE DATABASE LINK MyLink
CONNECT TO Database2 IDENTIFIED BY Password2
USING 'db2';
```

Exemple complet (2)

- Ou combiner tout sans devoir toucher au fichier tnsname.ora

```
CREATE DATABASE LINK MyLink
CONNECT TO Database2 IDENTIFIED BY Password2
USING '(DESCRIPTION=
        (ADDRESS_LIST=
            (ADDRESS=(PROTOCOL=TCP)(HOST=localhost)
                (PORT=1521) )
        )
        (CONNECT_DATA= (SERVER=DEDICATED)
            (SERVICE_NAME=xe) )
)';
```

Utilisation du DB Link

- Très simple, préciser le nom du DB Link après le nom de la table, et séparer les deux par '@'.

- Exemple :

```
SELECT *  
FROM MaTable@MyLink  
WHERE MaColonne > 5;
```

- Attention : La résolution du nom ne se fait qu'au moment de l'utilisation
 - Même avec un nom de service incorrect, ou une mauvaise adresse IP, la commande CREATE DATABASE LINK ne renverra pas d'erreur!

Agenda

- Problématique
- Business Intelligence
- Vers un SID
- Outils
- Concepts
- Modélisation
- Erreurs fréquentes
- Jobs

- Que deviennent les informations opérationnelles une fois qu'elles ont servi ?
 - Détruites ? Archivées ? Éparses ?
 - Potentiel de ces données ?

« Une somme de connaissances en constante accumulation est aujourd'hui éparpillée de par le monde. Elle suffirait probablement à résoudre toutes les grandes difficultés de notre temps, si elle n'était dispersée et inorganisée. »

H.G. Wells, « Mankind in the making », 1940


Problématique

- But recherché :
 - Améliorer les performances décisionnelles de l'entreprise en répondant aux demandes d'analyse des décideurs *non informaticiens et non statisticiens*
- Exemple :
 - Analyse clientèle :
 - Qui sont mes clients ? Pourquoi sont-ils mes clients ?
 - Comment les conserver ou les faire revenir ?
 - Marketing, actions commerciales :
 - Où placer ce produit dans les rayons ? Comment cibler plus précisément le mailing concernant ce produit ?

Mise en oeuvre

- Nécessité de rapport pour tout formaliser
- Nécessité de vues personnalisée en fonction des utilisateurs
- Globalisation et agrégation de certaines informations (ventes, ...)
- Notion dans le temps

Pyramide d'Anthony



Business Intelligence (BI)

- Concept proposé par IBM, Microsoft, Oracle, ...
 - *Consolider la quantité gigantesque de données atomiques que les entreprises génèrent en information pour que les gens puissent les accéder, les comprendre et les utiliser'*
 - *=> Présenter l'information dans des formats plus utiles, en utilisant des outils d'exploration, de reporting et de visualisation avancés*

Système d'information opérationnel (SIO)

- Constat :
 - Opérations essentielles : encodage et consultation d'informations
 - Nombre de transactions par seconde, volume des transactions par utilisateurs → très élevé
 - Base de données bien opérationnelle
- Postulat :
 - La société possède déjà plusieurs magasins
- Objectif :
 - implantation de nouvelles succursales
- Questions....

Caractéristiques du Data warehouse (DW)

- Un schéma différent ?
 - L'utilisateur veut des indicateurs, des corrélations, des croisements, etc....
 - ⇒ vue sur les données radicalement indépendante des structures du SIO

Pourquoi une autre BD ?

- Dans un système d'information décisionnel (SID), les performances transactionnelles et la sauvegarde de l'intégrité sont sans objet
 - Pas d'activité transactionnelle
 - Uniques mises à jours = alimentation du DW
 - ⇒ La redondance n'est pas un problème
 - ⇒ donner une structure conforme au point de vue utilisateur

Niveau de détail de l'information

- SIO :
 - Informations élémentaires liées à une opération du système réel
 - Montant facturé à UNE facture
 - Prix lié à UN produit,
 - Adresse d'UN client
 - ...
- SID :
 - Information élaborée sur des données dérivées et/ou de consolidation sur les données élémentaires


Représentation du temps

- SIO :
 - Données = état présent
 - Bd dans un état cohérent
 - « unité de temps » = transaction atomique
 - temps implicite
 - dynamique inscrite dans ses traitements
- SID
 - Articulé sur la mémoire d'entreprise
 - N'a de sens que s'il peut brasser des infos à LT
 - affecte le contenu
 - affecte la structure de la BD

Exemple

- Immatriculation


Vehicule
<u>NumImmatriculation</u>
Marque
Modèle
Cylindree
Puissance
id: NumImmatriculation



Outils de la BI

- Ces outils répondent à 3 besoins :
 - Collecter, nettoyer, consolider les données de l'entreprise étendue
 - ➔ outils ETL
 - Stocker les données
 - ➔ DW ou DM
 - Exploiter l'information
 - ➔ applications clientes

Outils de la BI



Collecter : Extract Transform Load (ETL)

- Constat :
 - Disparité des formats de données
 - Systèmes hétérogènes
- Solution :
 - Formatage
 - Nettoyage
 - Consolidation
- *Extract, transform and load*
 - Chargé d'extraire les données dans différentes sources, de les nettoyer et de les charger dans un entrepôt de données.

Stocker : DW ou Datamart (DM)

- Conçus pour **centraliser des informations** toutes sources confondues en vue de fournir une vision globale de l'état d'entreprise
- Lieu de **stockage intermédiaire** des différentes données en vue de la constitution du système d'information décisionnel
- Lieu de **consolidation** de l'ensemble des données de l'entreprise.

Exploiter : OLTP

On-Line Transaction Processing

- Cible des BD relationnelles
- Mise à jour ponctuelle des BD
- Peu de lignes à la fois
- Faible quantité d'information échangée

Exploiter : OLAP

On-Line Analytical Processing

- Permettre une analyse sur des bases de données volumineuses afin de mettre en évidence une analyse particulière des données.
- Création de représentations multidimensionnelles (hypercubes)

Exploiter : Evolution du concept

- R-OLAP (Relational OLAP)
- D-OLAP (Dynamic ou Desktop OLAP)
- M-OLAP (Multidimensional OLAP)
- H-OLAP (Hybrid OLAP)
- S-OLAP (Spatial OLAP)

Exploiter : DataMining


« forage de données »

- But : mettre en évidence des corrélations éventuelles dans un volume important de données afin de dégager des tendances
- Mettre en évidence des liens cachés


Modèle en étoile

- La table de faits :
 - Sert à stocker les mesures de l'activité.
 - Chaque mesure est prise à l'intersection de toutes les tables de dimensions.
- Remarque :
 - Faits : Numériques, additifs (mais pas obligatoirement)
 - Table éparses
- Table de dimension :
 - Sert à enregistrer des descriptions textuelles des activités de l'entreprise


Modèle en étoile



Modèle en flocons




Modèle en galaxie / constellation



Hypercube


- Modélisation multidimensionnelle
- Facilite l'analyse d'une quantité selon différentes dimensions
- Plusieurs axes d'analyses
- Exple :
 - Tables relatives aux ventes de chaque année entre 1997 et 1999
 - 3 dimensions : catégorie/produits/temps

Hypercube



Roll up / drill down

- Permet d'accéder à une vue plus ou moins détaillée des données. On dit que l'on accède à un membre(un niveau) d'une dimension.



Rotate / pivot

- Permet d'accéder aux données concernant un fait, selon un axe d'analyse (une dimension) différent.

	2008	2009	2010
IR	200	180	150
GC	40	90	230



	2008	2009	2010
UMLV	200	180	150
ENSAM	40	90	230


Slicing

- Permet d'accéder aux données concernant un fait, selon une partie des axes d'analyse (des dimensions) choisis.

	2008	2009	2010
IR	200	180	150
GC	40	90	230



		2009
IR	UMLV	180
	ENSAM	0





Scoping / dicing

- Permet d'accéder aux données concernant un fait, en choisissant le niveau de détail désiré, pour chaque axe d'analyse (dimension) choisi.

	2008	2009	2010
IR	200	180	150
GC	40	90	230



		2009	2010
IR	UMLV	180	150
	ENSAM	0	0



Schedulers

- Parfois, une tâche doit s'exécuter de manière périodique sans intervention de l'utilisateur
 - Mise à jour vers un entrepôt de données
 - Sauvegarde automatique
 - Suppression des données temporaires
 - ...
- Toujours possible d'avoir une application qui lance une procédure à intervalle régulier
- Mieux : Scheduleur

dbms_scheduler

- Permet de programmer l'exécution d'un job
- Syntaxe :

```
dbms_scheduler.create_job(  
paramètre1 => valeur1,  
paramètre2 => valeur2,  
...  
);
```

Paramètres

- Il en existe 37
 - Nous ne les verrons pas tous dans ce cours
- Les plus courants (et utiles)
 - Job_name : le nom du job (référence à réutiliser)
 - Job_type : type du job (exécutable, procédure stockée, code PL/SQL, ...)
 - Job_action : lien vers la ressource à exécuter
 - Repeat_interval : décrit la fréquence d'exécution
 - Start_date/end_date : date de début et de fin d'exécution
 - Comments : commentaires
 - Auto_drop : indique s'il faut supprimer le job après exécution (par défaut : oui !)
 - Enabled : indique si le job doit s'exécuter (par défaut : non !)
 - Restart_on_recovery : indique si le job doit redémarrer en même temps que la BD (par défaut : non !)

job_type et job_action

- Détermine le type de job et ce qu'il doit exécuter

job_type	job_action
'PLSQL_BLOCK'	Script PL/SQL
'STORED_PROCEDURE'	Nom de la procédure
'EXTERNAL_SCRIPT'	Chemin vers le fichier script ou script inline
'SQL_SCRIPT'	Chemin vers le fichier .sql ou code SQLPlus inline
...	...

- Parfois besoin de spécifier les credentials

repeat_interval

- Syntaxe

```
repeat_interval => `  
paramètre1=valeur1;  
paramètre2=valeur2;  
...` ,
```

- Où

- FREQ = ("YEARLY" | "MONTHLY" | "WEEKLY" | "DAILY"
| "HOURLY" | "MINUTELY" | "SECONDLY")
- BYMONTH = (1 | 2 | ... | 12)
- BYDAY = ("MON" | "TUE" | "WED" | "THU" | "FRI" |
"SAT" | "SUN")
- BYHOUR = 0 ➔ 23
- BYMINUTE = 0 ➔ 59
- BYSECOND = 0 ➔ 59
- ...

Permissions

Dans sys

```
GRANT CREATE JOB TO HR;
```

```
GRANT MANAGE SCHEDULER TO HR;
```

Exemple : Bloc PL/SQL

Création du job

```
BEGIN
  dbms_scheduler.create_job(
    job_name => 'FirstTest',
    job_type => 'PLSQL_BLOCK',
    job_action => 'BEGIN insert into log values(1, ''test'');
                  commit;  END;',
    start_date => NULL,
    repeat_interval => 'FREQ=DAILY; BYHOUR=9; BYMINUTE=15',
    auto_drop => FALSE,
    comments => 'First test',
    enabled => true
  );
END;
```

Autre actions sur les jobs

- Vérifier que le job existe bien

```
select * from user_scheduler_jobs;
```

- Forcer l'exécution du job

```
begin
    dbms_scheduler.run_job(
        job_name => 'FirstTest'
    );
END;
```

Autres actions sur les jobs (2)

- Supprimer le job

```
BEGIN
```

```
    dbms_scheduler.drop_job(  
        job_name => 'FirstTest',  
        force => true  
    );
```

```
END;
```

Attention aux erreurs

```
BEGIN
dbms_scheduler.create_job(
    job_name => 'FirstTest',
    job_type => 'PLSQL_BLOCK',
    job_action => 'BEGIN insert into logue
values(1, 'test'); commit; END;',
    start_date => NULL,
    repeat_interval => 'FREQ=DAILY; BYHOUR=16;
BYMINUTE=35',
    auto_drop => FALSE,
    comments => 'First test',
    enabled => true
);
END;
```

➔ Procédure PL/SQL terminée. (pas d'erreurs)

Attention aux erreurs (2)

- `select job_name, run_count from user_scheduler_jobs where job_name = 'FIRSTTEST';`

	JOB_NAME	RUN_COUNT
1	FIRSTTEST	1

 (s'est bien exécuté)

- `select * from log;`
 • ➔ aucun résultat

- `Begin dbms_scheduler.run_job('FirstTest'); END;`

```

Erreur commençant à la ligne: 36 de la commande -
begin
  dbms_scheduler.run_job(
    job_name => 'FirstTest'
  );
END;
Rapport d'erreur -
ORA-06550: Ligne 1, colonne 775 :
PL/SQL: ORA-00942: Table ou vue inexistante
ORA-06550: Ligne 1, colonne 763 :
PL/SQL: SQL Statement ignored
ORA-06512: à "SYS.DBMS_ISCHED", ligne 242
ORA-06512: à "SYS.DBMS_SCHEDULER", ligne 566
ORA-06512: à ligne 2
06550. 00000 - "line %s, column %s:\n%s"
*Cause:      Usually a PL/SQL compilation error.
*Action:
    
```

Utilisation d'une procédure stockée

- Exemple:

```
create or replace PROCEDURE add_log
IS
    maxId NUMBER;
BEGIN
    LOCK TABLE log IN EXCLUSIVE MODE;
    SELECT MAX(id) into maxId FROM log;
    INSERT INTO log VALUES (COALESCE(maxId+1,1),
`test`);
    commit;
END add_log;
```

Création du job

```
BEGIN
dbms_scheduler.create_job(
    job_name => 'SecondTest',
    job_type => 'STORED_PROCEDURE',
    job_action => 'add_log',
    start_date => NULL,
    repeat_interval => 'FREQ=SECONDLY; INTERVAL=5',
    auto_drop => FALSE,
    comments => 'Second test',
    enabled => true
);
END;
```

- Ce job va donc s'exécuter toutes les 5 secondes

Paramètres?

- Un peu de polymorphisme

```
create or replace PROCEDURE add_log (text
varchar2)
IS
    maxId NUMBER;
BEGIN
    LOCK TABLE log IN EXCLUSIVE MODE;
    SELECT MAX(id) into maxId FROM log;
    INSERT INTO log VALUES (COALESCE(maxId+1,1),
text);
    commit;
END add_log;
```

Job avec paramètres

- Le plus simple : bloc PL/SQL

```
BEGIN
dbms_scheduler.create_job(
    job_name => 'ThirdTest',
    job_type => 'PLSQL_BLOCK',
    job_action => 'BEGIN add_log(''parametre''); END;',
    start_date => NULL,
    repeat_interval => 'FREQ=SECONDLY; INTERVAL=5',
    auto_drop => FALSE,
    comments => 'Third test',
    enabled => true
);
END;
```

- Utilité néanmoins limitée (toujours le même paramètre).
- A noter que paramètres OUT ou INOUT non pris en charge